

MINISTERUL EDUCAȚIEI ȘI CERCETĂRII
UNIVERSITATEA „1 DECEMBRIE 1918” DIN ALBA IULIA
FACULTATEA DE INFORMATICĂ ȘI INGINERIE
SPECIALIZAREA INFORMATICĂ
FORMA DE ÎNVĂȚĂMÂNT ZI

LUCRARE DE LICENȚĂ

COORDONATOR:

Lect. univ. drd. **Incze Arpad**

ABSOLVENT

Serbicean Alexandru

ALBA IULIA

2026

**MINISTERUL EDUCAȚIEI ȘI CERCETĂRII
UNIVERSITATEA „1 DECEMBRIE 1918” DIN ALBA IULIA
FACULTATEA DE INFORMATICĂ ȘI INGINERIE
SPECIALIZAREA INFORMATICĂ
FORMA DE ÎNVĂȚĂMÂNT ZI**

**SISTEM INTELIGENT PENTRU DETECTAREA
DEȘEURILOR ÎN SPAȚII VERZI UTILIZÂND
PROCESAREA IMAGINILOR VIDEO**

COORDONATOR:

Lect. univ. drd. Incze Arpad

ABSOLVENT

Serbicean Alexandru

ALBA IULIA

2026

CUPRINS

Introducere	4
Motivația alegerii temei	4
Obiectivele generale ale lucrării	5
Contribuțiile lucrării	6
Metodologia de cercetare folosită	6
Limitele lucrării	8
Structura lucrării	9
CAPITOLUL 1. Contextul Problemei și Cerințele Domeniului	11
1.1 Problematica deșeurilor în spații verzi și publice	11
1.2 Necesitatea monitorizării automate prin analiză video	12
1.3 Sisteme inteligente pentru detecția obiectelor abandonate	13
1.4 Concepte și termeni utilizați în lucrare	14
CAPITOLUL 2. Fundamente Teoretice și Tehnologii Utilizate	17
2.1 Viziune artificială și rețele neuronale convoluționale	17
2.2 Detecția obiectelor și familia de modele YOLO	18
2.3 Clasificarea imaginilor și estimarea materialului	19
2.4 Tracking multi-obiect și analiză temporală	19
2.5 Metrice de evaluare pentru modele de viziune artificială	20
2.6 Tehnologii web, baze de date și comunicare client-server	21
CAPITOLUL 3. Date, Antrenarea Modelelor și Metodologia Experimentală	23
3.1 Sursele de date și selecția exemplelor	23
3.2 Curățarea, etichetarea și organizarea seturilor	24
3.3 Antrenarea detectorului de deșeuri	25
3.4 Antrenarea clasificatorului de material	25
3.5 Metodologia de evaluare experimentală	26
CAPITOLUL 4. Proiectarea și Implementarea Sistemului	27
4.1 Cerințe funcționale și non-funcționale	27
4.2 Arhitectura generală a aplicației	28
4.3 Integrarea pipeline-ului ML în aplicație	29
4.4 Algoritmul temporal pentru semnalarea incidentelor	30
4.5 Backend, bază de date și securizarea platformei	31
4.6 Interfața web și fluxurile de utilizare	33
4.7 Gestionarea dovezilor și protecția datelor	35
CAPITOLUL 5. Testare, Rezultate și Interpretare	37
5.1 Strategia de testare a sistemului	37
5.2 Evaluarea detectorului de deșeuri	37
5.3 Evaluarea clasificatorului de material	39
5.4 Evaluarea fluxului video și a algoritmului temporal	40
5.5 Validarea funcțională a aplicației web	42
5.6 Analiza erorilor și interpretarea rezultatelor	44
5.7 Direcții viitoare de dezvoltare	45
Concluzii	47
Sinteza rezultatelor obținute	47
Contribuții personale	47
Limitări și direcții viitoare	48
BIBLIOGRAFIE	49

INTRODUCERE

Motivația alegerii temei

Spațiile verzi și zonele publice deschise sunt printre cele mai vizibile părți ale unui oraș. Ele sunt folosite zilnic pentru deplasare, recreere, sport sau odihnă și influențează direct felul în care este percepută calitatea vieții urbane. Din acest motiv, întreținerea lor nu ține doar de aspectul estetic, ci și de confortul comunității, siguranța utilizării și responsabilitatea față de mediu. În practică, însă, aceste spații sunt afectate frecvent de obiecte abandonate: ambalaje, hârtii, sticle, doze metalice, pungi sau alte resturi de dimensiuni reduse.

La prima vedere, un astfel de obiect poate părea nesemnificativ. Totuși, acumularea deșeurilor în parcuri, pe alei sau în zone publice deschise produce efecte care se observă rapid: crește costul activităților de curățenie, reduce atractivitatea spațiului, creează disconfort pentru cetățeni și poate încuraja repetarea aceluiași comportament. La nivel european, statisticile privind deșeurile municipale sunt urmărite constant deoarece acestea reflectă atât modelele de consum, cât și modul în care colectarea și tratarea deșeurilor sunt organizate administrativ [1]. Pentru administratorii spațiilor publice, dificultatea nu constă doar în curățarea locului, ci și în identificarea rapidă a momentelor și zonelor în care apar incidentele.

Monitorizarea clasică se bazează, de regulă, pe patrulare periodice, sesizări ale cetățenilor sau camere video folosite mai ales pentru înregistrare pasivă. Aceste metode sunt utile, dar au limite clare. O patrulă nu poate acoperi permanent toate zonele, o sesizare apare de obicei după producerea incidentului, iar o cameră video nu rezolvă problema dacă materialul trebuie verificat manual. O persoană responsabilă poate fi nevoită să urmărească înregistrări lungi pentru a observa un obiect mic, apărut într-o zonă aglomerată sau într-un colț al cadrului. În asemenea situații, oboseala, volumul mare de date și schimbările subtile ale scenei pot duce ușor la omisiuni.

Evoluția viziunii artificiale oferă o soluție potrivită pentru acest tip de problemă. Modelele moderne de detecție a obiectelor pot localiza automat elemente de interes în imagini și cadre video, iar familia YOLO este folosită frecvent în aplicații în care viteza de procesare trebuie echilibrată cu acuratețea [2], [3]. În același timp, seturi de date precum TACO arată că identificarea obiectelor de tip deșeu în contexte reale este o problemă relevantă și studiată în comunitatea de viziune artificială [4]. Diferența importantă, în cazul lucrării de față, este că simpla detectare a unui obiect într-o imagine nu este suficientă. O hârtie poate exista deja în scenă, o pungă poate fi deplasată de vânt, iar o sticlă poate fi confundată parțial cu fundalul. Pentru a vorbi despre un posibil incident, este

nevoie de context video: apariția obiectului, prezența unei persoane, evoluția poziției și stabilizarea obiectului în zona monitorizată.

Motivația alegerii temei vine tocmai din această combinație între o problemă practică și un set de tehnologii informatice care pot fi integrate într-un sistem coerent. Lucrarea nu tratează doar recunoașterea unei imagini statice, ci proiectarea unui flux complet: detecția obiectelor de tip deșeu, estimarea materialului, analiza temporală a scenei, salvarea dovezilor locale și validarea incidentelor într-o aplicație web. Prin această abordare, sistemul propus poate reduce timpul necesar verificării manuale și poate ajuta utilizatorul responsabil să se concentreze pe momentele relevante, fără ca decizia finală să fie transferată complet către modelul automat.

Obiectivele generale ale lucrării

Scopul lucrării este proiectarea, implementarea și evaluarea unui sistem informatic pentru detectarea deșeurilor în spații verzi, utilizând analiza imaginilor video. Sistemul urmărește localizarea obiectelor de tip deșeu, estimarea materialului din care acestea sunt realizate și semnalarea unor posibile incidente prin corelarea detecțiilor cu prezența persoanelor și cu evoluția scenei în timp. Rezultatul practic este o aplicație web locală, cu rol de prototip funcțional, în care utilizatorii pot monitoriza surse video, pot consulta incidentele generate automat și pot confirma, respinge sau arhiva dovezile asociate.

Pentru atingerea acestui scop, sunt urmărite următoarele obiective specifice:

- analiza conceptelor teoretice necesare: viziune artificială, rețele neuronale convoluționale, detecția obiectelor, clasificarea imaginilor și procesarea secvențelor video;
- studierea surselor de date disponibile și pregătirea unui set relevant pentru scenarii de monitorizare a deșeurilor în spații verzi;
- filtrarea exemplelor necorespunzătoare și organizarea datelor în subseturi distincte de antrenare, validare și testare;
- antrenarea prin transfer learning a unui detector de obiecte bazat pe arhitectura YOLOv8s, destinat localizării deșeurilor în imagini;
- utilizarea unui clasificator pentru estimarea materialului obiectelor detectate, în categorii precum plastic, hârtie, sticlă, metal și alte materiale;
- integrarea unui detector de persoane și proiectarea unei logici temporale care analizează relația dintre prezența umană și apariția unui obiect de tip deșeu;

- dezvoltarea unei aplicații web cu autentificare, roluri de acces, monitorizare video, listă de incidente, validare umană și păstrarea locală a dovezilor;
- evaluarea componentelor dezvoltate prin metrici specifice, precum precizie, recall, scor F1, mAP@50, mAP@50–95 și acuratețe;
- identificarea limitărilor sistemului și formularea unor direcții de îmbunătățire pentru scenarii mai apropiate de utilizarea operațională.

Contribuțiile lucrării

Contribuția principală a lucrării constă în realizarea unui sistem aplicativ care combină vi-ziunea artificială, analiza temporală și dezvoltarea web într-un flux de monitorizare verificabil. Sistemul nu se oprește la afișarea unor casete de detecție peste imagine, ci încearcă să transforme aceste detecții în evenimente gestionabile. În loc să considere fiecare obiect detectat drept inci-dent, aplicația urmărește succesiunea cadrelor și păstrează doar situațiile care merită analizate de utilizatorul responsabil.

Contribuțiile concrete includ pregătirea datelor pentru detecția deșeurilor, antrenarea și in-tegrarea unui detector YOLOv8, folosirea unui clasificator pentru material, integrarea detecției persoanelor, proiectarea unei logici temporale pentru semnalarea incidentelor și dezvoltarea unei aplicații web prin care rezultatele pot fi vizualizate, validate și arhivate. O contribuție importantă este separarea clară dintre sistemul automat și decizia umană. Aplicația nu emite constatări oficia-le și nu stabilește vinovății; ea furnizează indicii tehnice și dovezi locale care pot fi analizate de o persoană responsabilă.

Din punct de vedere tehnic, lucrarea reunește componente care, luate separat, sunt relativ cu-noscute: modele de învățare automată, procesare video, urmărirea obiectelor în timp, bază de date, autentificare și interfață web. Valoarea proiectului stă în integrarea lor într-un prototip funcțional, orientat către o problemă concretă. Astfel, rezultatul nu este doar un experiment de laborator, ci o aplicație capabilă să gestioneze un flux complet: de la cadru video, la detecție, incident, dovadă și validare.

Metodologia de cercetare folosită

Metodologia lucrării este aplicativ-experimentală. În prima etapă sunt analizate conceptele teoretice necesare pentru înțelegerea soluției: detecția obiectelor, clasificarea imaginilor, învățarea prin transfer, metricile de evaluare, trackingul multi-obiect și analiza temporală a secvențelor video.

Fundamentarea teoretică se bazează pe lucrări consacrate din domeniul detecției obiectelor și pe seturi de date utilizate frecvent în viziunea artificială, precum TACO și COCO [4], [5].

În etapa experimentală, datele disponibile sunt analizate și filtrate pentru a obține un set mai apropiat de scopul lucrării. Nu toate imaginile colectate din surse publice sunt utile pentru scenariul urmărit: unele conțin etichete zgomotoase, obiecte prea mici, contexte irelevante sau situații care pot afecta stabilitatea modelului. Din acest motiv, pregătirea datelor este tratată ca parte esențială a proiectului, nu ca o activitate secundară. Setul final este împărțit în subseturi de antrenare, validare și testare, astfel încât performanța să poată fi analizată pe exemple care nu au fost folosite pentru ajustarea modelului.

Antrenarea detectorului se realizează prin transfer learning, nu prin proiectarea unei arhitecturi neuronale de la zero. Această alegere este potrivită pentru o lucrare de licență, deoarece permite valorificarea unor modele preantrenate, capabile să extragă caracteristici vizuale generale. Adaptarea lor la domeniul deșeurilor face posibilă obținerea unui detector specializat cu un volum realist de date și cu resurse hardware accesibile. Clasificarea materialului este tratată separat, fiind aplicată asupra regiunilor de interes generate de detector.

Componenta aplicativă este dezvoltată ca sistem web local, cu posibilitatea de extindere ulterioară către un mediu de server. Backend-ul gestionează autentificarea, baza de date, inferența modelelor, fluxul video și retenția dovezilor, iar frontend-ul oferă interfețe pentru monitorizare, administrare și validarea incidentelor. În cadrul fluxului video, sistemul combină detecția deșeurilor cu detecția persoanelor și cu o logică temporală, deoarece un incident nu poate fi interpretat corect dintr-un singur cadru izolat.

Evaluarea este gândită pe mai multe niveluri. Modelele sunt analizate prin metrice specifice viziunii artificiale, aplicația prin teste funcționale și scenarii de utilizare, iar algoritmul temporal prin clipuri video care permit observarea reacției la apariția obiectelor și la deplasarea persoanelor. Această separare permite identificarea mai clară a punctelor forte și a limitărilor: o eroare poate proveni din detector, din clasificator, din calitatea clipului sau din regulile temporale folosite pentru semnalarea incidentului.

Din punct de vedere al mediului de lucru, experimentele au fost realizate pe un calculator personal cu placă video NVIDIA GeForce RTX 3050 cu 4 GB de memorie, configurație reprezentativă pentru resursele accesibile unui student sau unei instituții mici. Antrenarea și inferența modelelor folosesc biblioteca Ultralytics peste PyTorch, cu accelerare CUDA atunci când placa video este disponibilă și revenire automată pe procesor în caz contrar. Componenta aplicativă folosește FastAPI pentru backend, SQLite pentru persistența locală și OpenCV pentru prelucrarea cadrelor video. Alegerea unor unelte open-source, larg documentate, susține caracterul reproductibil al

lucrării: experimentele pot fi reluate pe o configurație similară fără licențe sau servicii externe.

Tot în sprijinul reproductibilității, lucrarea păstrează o separare strictă între artefactele experimentale și cele de producție. Modelele promovate în aplicație sunt stocate în directoare dedicate, distincte de directoarele de experimente, iar seturile de date au împărțiri fixe, cu același seed, astfel încât orice re-rulare a evaluării să producă aceleași subseturi. Pragurile de încredere, dimensiunile de inferență și parametrii algoritmului temporal sunt centralizați în configurația aplicației, ceea ce permite ajustarea lor controlată și documentarea valorilor folosite în teste.

Limitele lucrării

Lucrarea are câteva limite care trebuie menționate de la început. Performanța sistemului depinde de calitatea imaginilor video: rezoluția camerei, unghiul de filmare, iluminarea, distanța față de obiect, mișcarea persoanelor și nivelul de aglomerație influențează direct rezultatele. Un obiect mic, parțial acoperit sau aflat într-o zonă slab luminată poate fi mai dificil de detectat decât un obiect clar vizibil în prim-plan.

Sistemul nu trebuie interpretat ca o soluție juridică automată. Detectarea unui obiect de tip deșeu și semnalarea unui posibil incident reprezintă indicii tehnice, nu o constatare oficială. Rolul aplicației este de a reduce efortul de observare, de a salva dovezi relevante și de a oferi utilizatorului responsabil un punct de plecare pentru verificare. Decizia finală privind validarea incidentului trebuie să aparțină unei persoane responsabile.

Aria de utilizare este limitată la scenarii apropiate de datele folosite în antrenare și testare. Sistemul este orientat către spații verzi și zone publice deschise, însă nu garantează aceeași performanță în condiții dificile, precum filmare nocturnă, ploaie, zăpadă, aglomerație foarte mare sau camere amplasate la distanțe mari. Extinderea către astfel de situații ar necesita colectarea și etichetarea unor date suplimentare.

O altă limită este caracterul local și experimental al aplicației. Sistemul este gândit pentru rulare locală în contextul lucrării de licență, cu posibilitatea de configurare pentru un deploy ulterior pe server. Pentru utilizare operațională pe termen lung ar fi necesare măsuri suplimentare privind securitatea infrastructurii, administrarea certificatelor, politici detaliate de acces, monitorizare continuă și integrare cu sisteme externe ale autorităților sau administratorilor de spații verzi.

Trebuie menționată și ipoteza de operare a algoritmului temporal: sistemul presupune o cameră fixă, cu un cadru stabil al zonei monitorizate. Această ipoteză este firească pentru scenariul de supraveghere urmărit, însă restrânge tipurile de înregistrări pe care sistemul le poate interpreta corect. Filmările cu camera în mișcare, transfocările sau materialele editate cu tăieturi de scenă rup

continuitatea trackingului și fac imposibilă corelarea temporală dintre persoană și obiect. Din acest motiv, atât testarea live, cât și evaluarea pe clipuri din capitolul de testare respectă explicit această ipoteză, iar materialele care o încalcă sunt excluse motivat din scor.

În același registru, distanța de operare influențează direct performanța: un obiect de dimensiuni mici devine, la câțiva metri de cameră, o regiune de doar câteva zeci de pixeli, aflată la limita capacității de detecție. Testele practice efectuate în lucrare arată o funcționare fiabilă la distanțe de până la aproximativ 2–3 metri pentru camera unui telefon; extinderea acestui interval presupune camere cu rezoluție mai mare sau decuparea inteligentă a zonelor de interes, direcții discutate la finalul lucrării.

Structura lucrării

Lucrarea este organizată în cinci capitole. Primul capitol prezintă problema deșeurilor în spații publice, necesitatea monitorizării automate și termenii utilizați în continuare. Capitolul al doilea descrie fundamentele teoretice și tehnologiile folosite: viziunea artificială, detecția obiectelor, clasificarea imaginilor, trackingul, analiza temporală și tehnologiile web. Capitolul al treilea este dedicat datelor, antrenării modelelor și metodologiei experimentale. Capitolul al patrulea prezintă proiectarea și implementarea sistemului, incluzând arhitectura aplicației, integrarea pipeline-ului ML, algoritmul temporal, backend-ul, baza de date și interfața web. Capitolul al cincilea tratează testarea, rezultatele obținute, analiza erorilor și direcțiile de îmbunătățire. Lucrarea se încheie cu sinteza concluziilor, contribuțiile personale și limitările rămase.

Ordinea capitolelor urmează parcursul firesc al proiectului: de la delimitarea problemei și a conceptelor, prin pregătirea datelor și antrenarea modelelor, către integrarea lor într-o aplicație completă și, în final, către verificarea experimentală a întregului sistem. Fiecare capitol se sprijină pe cele anterioare, astfel încât cititorul să poată urmări atât raționamentul tehnic, cât și deciziile practice care au condus la forma finală a aplicației.

Lucrarea poate fi parcursă, de altfel, pe două planuri complementare. Primul este planul de învățare automată: datele, antrenarea modelelor și metricile de evaluare, tratate în principal în capitolele 3 și 5. Al doilea este planul ingineriei aplicației: arhitectura, fluxurile de utilizare, securitatea și gestionarea dovezilor, tratate în capitolul 4. Capitolele 1 și 2 leagă cele două planuri prin cerințele domeniului și prin fundamentele teoretice comune. Această dublă perspectivă reflectă natura proiectului: un model performant fără o aplicație în jurul lui rămâne un experiment de laborator, iar o aplicație fără un model evaluat riguros rămâne o simplă demonstrație — lucrarea urmărește să le susțină pe amândouă, cu aceeași atenție pentru reproducibilitate.

Pe lângă evaluarea finală, dezvoltarea aplicației a fost însoțită permanent de verificări automate și manuale. Proiectul include o suită de teste automate pentru componentele backend-ului — autentificare, reguli de acces, operații pe incidente — rulată după fiecare modificare importantă, precum și scripturi de verificare rapidă pentru pipeline-ul de inferență și pentru fluxul video complet. Acest mod de lucru a permis identificarea timpurie a unor defecte subtile, cum ar fi pierderea clipului de dovadă atunci când două incidente apăreau la interval foarte scurt, și corectarea lor înainte de evaluarea finală. Într-un sistem cu multe componente interdependente, în care o modificare a algoritmului temporal poate afecta indirect salvarea dovezilor sau raportarea statisticilor, această disciplină de verificare s-a dovedit la fel de importantă ca alegerea modelelor în sine. Capitolul de testare reia aceste aspecte în mod sistematic, de la metricile modelelor până la validarea funcțională a aplicației web în ansamblu.

CAPITOLUL 1

CONTEXTUL PROBLEMEI ȘI CERINȚELE DOMENIULUI

1.1 Problematica deșeurilor în spații verzi și publice

Spațiile verzi, parcurile, aleile pietonale și zonele publice deschise fac parte din infrastructura de bază a unui oraș. Ele nu sunt doar zone decorative, ci locuri folosite constant de cetățeni: pentru deplasare, odihnă, activități sportive sau interacțiune socială. Calitatea acestor spații influențează direct imaginea orașului și confortul celor care le utilizează. Din această perspectivă, prezența deșeurilor abandonate reprezintă o problemă practică, vizibilă și greu de ignorat.

În mod obișnuit, deșeurile întâlnite în astfel de zone sunt obiecte mici sau medii, precum ambalaje, hârtii, pungi, doze metalice, sticle ori resturi alimentare. Dimensiunea redusă face ca ele să fie ușor de aruncat, dar și ușor de pierdut în fundalul scenei. O pungă poate avea o formă neregulată, o hârtie poate fi confundată cu o zonă luminată de pe alee, iar o sticlă transparentă poate deveni greu vizibilă în funcție de unghiul camerei. Aceste detalii, aparent simple pentru un observator aflat la fața locului, devin mai dificile atunci când scena este analizată automat dintr-un flux video.

Problema nu este doar una de curățenie. Din punct de vedere administrativ, administratorii spațiilor publice trebuie să identifice zonele în care apar frecvent incidente, să intervină rapid și să poată documenta situațiile relevante. În lipsa unei monitorizări eficiente, activitatea de întreținere rămâne reactivă: se intervine după ce problema este observată, raportată sau acumulată. În schimb, un sistem capabil să semnaleze rapid apariția unui posibil incident poate ajuta la reducerea timpului de reacție și la organizarea mai bună a intervențiilor.

În această lucrare, termenul de deșeu desemnează un obiect vizibil în imagine, aparținând unei categorii materiale relevante pentru monitorizare: plastic, hârtie, sticlă, metal sau alte materiale similare. Lucrarea nu urmărește întregul proces de management al deșeurilor, cum ar fi colectarea, transportul, reciclarea sau planificarea infrastructurii de salubritate. Accentul este pus pe o etapă mai restrânsă, dar importantă: identificarea automată a obiectelor de tip deșeu în cadre video și semnalarea situațiilor în care apariția lor poate indica un incident de aruncare sau abandonare.

Această delimitare este esențială: problema abordată nu este doar detecția statică a deșeurilor, ci interpretarea lor în context video. Sistemul trebuie să observe modificarea scenei, să coreleze

aparitia obiectului cu prezenta unei persoane si sa ofere utilizatorului responsabil o dovada locala care poate fi verificata.

Din perspectiva viziunii artificiale, recunoasterea deseurilor in contexte naturale este o problema dificila. Setul de date TACO evalueaza diversitatea mare a obiectelor de tip litter si dificultatile produse de iluminare, fundal, perspectiva si ocluzie [4]. Studii recente dedicate detectiei deseurilor in medii naturale si urbane confirma faptul ca problema nu se reduce la clasificarea unor obiecte izolate, ci presupune date realiste, categorii materiale variate si evaluare in contexte vizuale dificile [6]. Spre deosebire de seturi generale precum COCO sau PASCAL VOC, unde multe categorii de obiecte au forme relativ stabile si apar frecvent in prim-plan [5], deseurile din spatii publice pot fi mici, deformate, partial acoperite sau foarte asemănătoare cu elementele mediului. Acest lucru justifica folosirea unei solutii adaptate domeniului si testate pe scenarii apropiate de utilizarea dorita.

1.2 Necesitatea monitorizării automate prin analiză video

Monitorizarea clasica a spatiilor verzi se realizeaza prin patruli, verificari periodice, sesizari ale cetatenilor sau camere video. Fiecare dintre aceste metode are utilitate, dar niciuna nu rezolva complet problema observarii continue. Patrurile sunt limitate de timp si personal, sesizarile apar dupa producerea incidentului, iar camerele video devin eficiente doar daca exista un mod practic de analiza a materialului inregistrat. O camera care doar stocheaza imagini nu reduce, in sine, efortul de verificare.

Analiza video automată schimbă rolul camerei. Aceasta nu mai este doar o sursă de înregistrare, ci o sursă de date care poate fi prelucrată în timp aproape real. Fiecare cadru poate fi analizat pentru localizarea obiectelor relevante, iar detectiile pot fi urmărite în timp pentru a observa dacă scena s-a modificat. În loc ca utilizatorul responsabil să urmărească permanent fluxul, sistemul poate semnaliza doar momentele care merită verificate și poate salva dovezile asociate.

Totuși, automatizarea nu elimină rolul omului. În contextul lucrării de față, sistemul nu este proiectat pentru a lua decizii juridice și nu stabilește sancțiuni. El funcționează ca un instrument de asistență: detectează, filtrează, salvează dovezi și propune incidente pentru validare. Utilizatorul responsabil verifică imaginea sau clipul asociat și decide dacă incidentul este confirmat, respins ca fals pozitiv sau arhivat. Această separare este importantă deoarece modelele de detecție pot greși, mai ales în scene reale, unde iluminarea, mișcarea, ocluziile și fundalul sunt greu de controlat.

Pentru ca o astfel de soluție să fie utilă, ea trebuie să îndeplinească mai multe cerințe. Sistemul trebuie să proceseze cadre video într-un timp rezonabil, să ofere rezultate ușor de verificat,

să păstreze dovezi locale și să permită administrarea clară a incidentelor. În același timp, trebuie să trateze cu atenție datele video, deoarece acestea pot conține persoane și informații sensibile. În lucrare, aceste cerințe sunt reflectate prin folosirea unui pipeline de detecție și clasificare, a unei logici temporale pentru semnalarea incidentelor și a unei aplicații web locale pentru monitorizare, validare și administrare.

Aceste cerințe arată că problema nu poate fi redusă la o singură etapă de inferență. Detecția obiectelor este necesară, dar nu suficientă. Sistemul trebuie să includă și mecanisme de interpretare temporală, interfață de validare, reguli de acces, stocare a dovezilor și posibilitatea de administrare a incidentelor. Tocmai această legătură dintre componente transformă modelul de inteligență artificială într-o aplicație utilizabilă.

Concret, domeniul impune șase cerințe care se regăsesc direct în proiectarea sistemului. Detecția vizuală automată este necesară deoarece monitorizarea manuală continuă este dificilă și consumatoare de timp; în lucrare, ea este acoperită de detectorul de deșeuri. Analiza temporală este necesară deoarece un obiect detectat într-un singur cadru nu confirmă un incident; ea este realizată prin corelarea apariției obiectului cu prezența persoanei și cu persistența obiectului în scenă. Validarea umană rămâne obligatorie deoarece scenele reale pot produce detecții greșite sau interpretări ambigue, astfel încât fiecare incident este confirmat, respins sau arhivat de utilizatorul responsabil. Dovezile locale permit verificarea ulterioară a evenimentului semnalat, prin imagine reprezentativă, clip scurt și metadata. Controlul accesului separă funcționalitățile pe roluri, deoarece nu toate acțiunile trebuie să fie disponibile tuturor utilizatorilor. În sfârșit, protecția datelor impune păstrarea controlată a dovezilor, deoarece fluxurile video pot conține persoane și informații sensibile.

1.3 Sisteme inteligente pentru detecția obiectelor abandonate

Sistemele inteligente bazate pe viziune artificială urmăresc extragerea automată a informațiilor relevante din imagini sau secvențe video. În cazul detecției obiectelor, scopul este localizarea și clasificarea unor entități vizibile în cadru. Modelele moderne de detecție folosesc rețele neuronale convoluționale, care au devenit o soluție standard în analiza imaginilor datorită capacității lor de a învăța caracteristici vizuale direct din date [7], [8].

În monitorizarea video, unde cadrele trebuie analizate succesiv, echilibrul dintre acuratețe și timp de procesare devine esențial. Din acest motiv, lucrarea utilizează familia YOLO, orientată către detecție rapidă, în implementarea Ultralytics YOLOv8, care oferă un cadru accesibil pentru antrenare, evaluare și inferență [2], [3]. Alegerea este importantă nu doar pentru performanța experimentală, ci și pentru integrarea într-o aplicație locală, unde resursele hardware pot fi limitate;

clasificarea detaliată a familiilor de modele de detecție și justificarea teoretică a acestei alegeri sunt prezentate în capitolul următor.

Cercetări recente propun și variante optimizate ale familiei YOLO pentru detectarea deșeurilor în scene complexe, inclusiv în zone urbane sau pe suprafețe cu fundal variabil [9]. Aceste rezultate susțin direcția aleasă în lucrare: folosirea unui detector rapid, urmată de verificare umană și de reguli suplimentare de interpretare temporală. Într-o aplicație de monitorizare, performanța modelului trebuie analizată împreună cu stabilitatea fluxului, calitatea dovezilor salvate și claritatea interfeței de validare.

Un sistem pentru detectarea obiectelor abandonate nu poate depinde însă doar de detectorul de deșeuri. Același obiect poate fi detectat în mai multe cadre consecutive, poate dispărea temporar din cauza unei persoane care trece prin fața camerei sau poate fi confundat cu elemente ale fundalului. Pentru a interpreta corect un posibil incident, sistemul trebuie să urmărească evoluția scenei. Algoritmii de tracking multi-obiect, cum este ByteTrack, evidențiază importanța asocierii detecțiilor între cadre pentru înțelegerea mișcării și persistenței obiectelor [10].

În această lucrare, ideea de obiect abandonat este modelată printr-o succesiune de observații. O persoană este prezentă în zona monitorizată, un obiect de tip deșeu apare sau devine stabil în cadru, iar scena indică posibilitatea ca obiectul să fi fost lăsat în urmă. Această logică nu pretinde să reconstruiască perfect intenția persoanei. Scopul ei este mai practic: reducerea numărului de momente pe care persoana responsabilă trebuie să le verifice manual și păstrarea dovezilor relevante pentru fiecare alertă.

Clasificarea materialului completează detecția. Pentru utilizatorul responsabil, informația că un obiect este estimat ca plastic, hârtie, sticlă sau metal poate ajuta la descrierea incidentului și la organizarea dovezilor. În sistemul propus, clasificarea este aplicată după localizarea obiectului, asupra regiunii de imagine corespunzătoare detecției. Astfel, incidentul nu conține doar poziția obiectului, ci și o descriere mai utilă pentru verificare.

1.4 Concepte și termeni utilizați în lucrare

Pentru claritatea lucrării, sunt definite principalele concepte folosite în capitolele următoare. Prin cadru video se înțelege o imagine individuală extrasă dintr-un flux video. Prin detecție se înțelege identificarea automată a unui obiect într-un cadru, împreună cu poziția acestuia. Poziția este reprezentată printr-o casetă de delimitare, numită frecvent bounding box, care indică zona din imagine în care modelul estimează prezența obiectului.

Fiecare detecție este însoțită de un scor de încredere. Acest scor nu reprezintă o certitudine

absolută, ci o estimare numerică produsă de model. Un prag de încredere prea mic poate produce multe alerte false, iar un prag prea mare poate omite obiecte reale. Din acest motiv, pragurile de detecție trebuie alese în funcție de scenariu și validate experimental. În lucrare, aceste aspecte sunt tratate în capitolele dedicate antrenării și testării modelelor.

Prin clasificare se înțelege atribuirea unei etichete unui obiect sau unei imagini. În cazul sistemului propus, clasificarea materialului se aplică obiectului detectat și urmărește categorii precum plastic, hârtie, sticlă, metal sau alte materiale. Prin tracking se înțelege urmărirea unei entități de la un cadru la altul, pentru a observa dacă aceasta persistă, se deplasează sau dispare. Trackingul este important deoarece incidentul nu poate fi interpretat corect dintr-o singură imagine.

Termenul de incident desemnează o situație semnalată de sistem în care apariția unui obiect de tip deșeu, corelată cu contextul temporal, sugerează o posibilă acțiune de aruncare sau abandonare. Incidentul nu este echivalent cu o constatare oficială. El este o alertă tehnică, însoțită de dovezi locale, care trebuie analizată de o persoană responsabilă. Prin dovadă locală se înțelege ansamblul format din metadate, imagine reprezentativă și clip video scurt asociat evenimentului.

În procesul de validare pot apărea două tipuri de erori. Un fals pozitiv apare atunci când sistemul semnalează un incident care, după verificare, nu reprezintă o aruncare ilegală reală. Un fals negativ apare atunci când un incident real nu este semnalat de sistem. Ambele tipuri de erori sunt importante. Falsurile pozitive afectează încrederea utilizatorului și pot încălca inutil panoul de administrare, iar falsurile negative reduc utilitatea practică a sistemului. De aceea, evaluarea trebuie să includă atât metrici ale modelelor, cât și observații asupra comportamentului sistemului pe clipuri video.

Intrarea principală a sistemului este un flux video sau un fișier video încărcat de utilizator. Ieșirea practică este o listă de incidente care pot fi vizualizate, filtrate și validate într-o interfață web locală. Fiecare incident conține informații despre momentul apariției, materialul estimat, scorurile relevante, statusul de validare și fișierele media asociate. Această structură permite legarea componentei de inteligență artificială de o aplicație utilizabilă, în care rezultatele nu rămân simple predicții, ci devin elemente gestionabile într-un flux de lucru.

Pe lângă acești termeni de bază, capitolele următoare folosesc câteva noțiuni specifice algoritmului temporal. Prin zona persoanei se înțelege ultima regiune din cadru în care o persoană a fost observată înainte de a părăsi scena; această zonă, extinsă cu o marjă procentuală, delimitează spațiul în care apariția unui obiect nou este considerată relevantă. Prin fereastra de monitorizare se înțelege intervalul de timp în care zona persoanei este supravegheată după plecarea acesteia. Fereastra de confirmare desemnează intervalul scurt dintre identificarea unui candidat de incident și emiterea efectivă a alertei, folosit pentru a anula cazurile în care persoana revine și ridică obiec-

tul. Perioada de cooldown reprezintă intervalul de după o alertă în care alertele suplimentare sunt suprimate, pentru a evita raportarea aceluiași eveniment de mai multe ori.

În concluzie, domeniul abordat de lucrare se află la intersecția dintre monitorizarea spațiilor publice, viziunea artificială și dezvoltarea aplicațiilor web. Capitolul de față a delimitat problema, a prezentat necesitatea monitorizării automate și a introdus termenii utilizați în continuare. Capitolul următor va detalia fundamentele teoretice și tehnologiile care permit implementarea soluției propuse.

CAPITOLUL 2

FUNDAMENTE TEORETICE ȘI TEHNOLOGII UTILIZATE

2.1 Viziune artificială și rețele neuronale convoluționale

Viziunea artificială este domeniul informaticii care urmărește extragerea automată a informațiilor din imagini și secvențe video. Într-un sistem de monitorizare, imaginea nu este tratată doar ca material vizual, ci ca o structură de date. Fiecare cadru video este compus din pixeli, iar fiecare pixel conține valori numerice care descriu intensitatea sau culoarea unei zone foarte mici din imagine. Prin prelucrarea acestor valori, sistemul poate identifica forme, contururi, texturi, obiecte și relații spațiale.

În cazul lucrării de față, viziunea artificială este folosită pentru analizarea cadrelor video provenite dintr-o cameră locală sau dintr-un fișier încărcat de utilizator. Scopul nu este doar recunoașterea unei imagini izolate, ci interpretarea unei scene în timp. Un obiect de tip deșeu poate fi vizibil într-un singur cadru, poate apărea treptat, poate fi parțial acoperit de o persoană sau poate fi confundat cu un element al fundalului. Din acest motiv, sistemul trebuie să combine analiza vizuală cu o logică temporală.

Rețelele neuronale convoluționale au devenit o soluție de bază pentru analiza imaginilor deoarece pot învăța automat caracteristici vizuale din date. În loc ca dezvoltatorul să definească manual reguli pentru fiecare formă sau textură, modelul învață filtre care răspund la elemente vizuale relevante. Primele straturi pot detecta margini, diferențe de culoare și forme simple, iar straturile mai adânci pot combina aceste informații în structuri mai complexe. Lucrările fundamentale privind rețelele convoluționale și utilizarea lor în recunoașterea imaginilor au contribuit decisiv la dezvoltarea aplicațiilor moderne de viziune artificială [7], [8].

Pentru un sistem aplicativ, avantajul principal al acestor modele este capacitatea de generalizare. Modelul nu memorează doar imaginile de antrenare, ci încearcă să identifice tipare care pot apărea și în exemple noi. Totuși, această generalizare depinde de calitatea datelor, de diversitatea exemplurilor și de modul în care modelul este evaluat. În domeniul deșeurilor, datele sunt mai dificile decât în clasificarea unor obiecte mari și bine centrate: obiectele pot fi mici, deformate, suprapuse cu fundalul sau surprinse în condiții diferite de iluminare.

În lucrare se folosește învățarea prin transfer. Aceasta pornește de la un model deja antrenat pe un volum mare de imagini și îl adaptează la domeniul urmărit. Abordarea este potrivită deoa-

rece antrenarea unui model profund de la zero necesită cantități mari de date și resurse hardware considerabile. Prin transfer learning, modelul poate reutiliza caracteristici vizuale generale și le poate ajusta pentru detectarea obiectelor de tip deșeu.

2.2 Detectția obiectelor și familia de modele YOLO

Detectția obiectelor reprezintă o sarcină mai complexă decât clasificarea unei imagini. În clasificare, modelul primește o imagine și returnează o etichetă pentru întreaga imagine. În detecție, modelul trebuie să indice atât clasa obiectului, cât și poziția acestuia în cadru. Poziția este exprimată printr-o casetă de delimitare, numită bounding box, care încadrează zona în care modelul estimează prezența obiectului.

Rezultatul unei detecții conține, de regulă, coordonatele casetei, clasa estimată și un scor de încredere. Scorul de încredere nu trebuie interpretat ca certitudine absolută, ci ca o estimare numerică produsă de model. În aplicații reale, alegerea pragului de încredere influențează direct comportamentul sistemului. Un prag prea mic poate produce multe detecții false, iar un prag prea mare poate elimina obiecte reale, mai ales dacă acestea sunt mici sau parțial vizibile.

Modelele pentru detecția obiectelor pot fi împărțite, în linii mari, în abordări în doi pași și abordări într-un singur pas. Modelele în doi pași, precum Faster R-CNN, propun mai întâi regiuni candidate și apoi clasifică obiectele din acele regiuni [11]. Acestea pot obține rezultate bune, dar au un cost computațional mai ridicat. Modelele într-un singur pas estimează direct pozițiile și clasele obiectelor, ceea ce le face mai potrivite pentru aplicații video, unde timpul de procesare contează.

Familia YOLO face parte din categoria detectorilor într-un singur pas și este cunoscută pentru orientarea către detecție rapidă [2]. În proiectul de față, această caracteristică este importantă deoarece fluxul video trebuie analizat cadru cu cadru, iar utilizatorul are nevoie de răspuns vizual într-un timp rezonabil. Implementarea Ultralytics YOLOv8 oferă un cadru practic pentru antrenare, evaluare și inferență, fiind folosită atât pentru detectorul de deșeuri, cât și pentru clasificatorul de material [3].

În sistemul realizat, detectorul de deșeuri este orientat către localizarea obiectelor relevante în cadru. El nu decide singur dacă a avut loc un incident. Detectia este prima etapă a unui pipeline mai amplu: obiectele detectate sunt analizate în timp, comparate cu prezența persoanelor, asociate cu un scor de încredere și trimise către interfața web doar atunci când condițiile temporale sugerează un eveniment relevant.

2.3 Clasificarea imaginilor și estimarea materialului

Clasificarea imaginilor este procesul prin care unui obiect, unei imagini sau unei regiuni de imagine i se atribuie o etichetă. În lucrare, clasificarea materialului este folosită după etapa de detecție. Mai întâi, detectorul localizează un obiect de tip deșeu, apoi zona corespunzătoare obiectului este decupată și transmisă unui clasificator. Clasificatorul estimează materialul obiectului: plastic, hârtie, sticlă, metal sau altă categorie relevantă.

Separarea detecției de clasificare are un avantaj practic. Detectorul se concentrează pe întrebarea „există un obiect de tip deșeu și unde se află?”, iar clasificatorul se concentrează pe întrebarea „ce material pare să aibă obiectul detectat?”. Într-o aplicație reală, această împărțire poate face fluxul mai ușor de interpretat și ajustat. Dacă detectorul localizează corect obiectul, dar clasificatorul greșește materialul, eroarea poate fi analizată separat.

Estimarea materialului nu are rol juridic și nu trebuie privită ca o identificare absolută. Un ambalaj transparent poate fi confundat cu sticlă sau plastic, o hârtie murdară poate avea culoare apropiată de fundal, iar o doză metalică poate fi parțial ascunsă. Din acest motiv, rezultatul clasificatorului este folosit ca informație auxiliară în incident, nu ca decizie finală. Utilizatorul responsabil poate verifica imaginea și clipul asociat înainte de confirmare.

În fluxul aplicației, clasificarea materialului îmbunătățește modul de descriere a incidentelor. În loc ca sistemul să afișeze doar o alertă generică, incidentul poate conține o estimare mai utilă pentru filtrare, raportare și analiză ulterioară. Această informație poate ajuta și la interpretarea rezultatelor experimentale, deoarece unele materiale pot fi mai greu de recunoscut decât altele.

2.4 Tracking multi-obiect și analiză temporală

Analiza unei imagini individuale nu este suficientă pentru identificarea unui posibil incident de aruncare ilegală. Într-un cadru izolat, sistemul poate observa un obiect de tip deșeu, dar nu poate stabili dacă obiectul era deja acolo, dacă a fost mutat, dacă a fost adus de vânt sau dacă a apărut în urma unei acțiuni umane. Pentru a apropia sistemul de scenarii reale, este necesară analiza temporală a secvenței video.

Trackingul multi-obiect urmărește asocierea detecțiilor de la un cadru la altul. Dacă un obiect este detectat în cadre consecutive, algoritmul încearcă să păstreze aceeași identitate pentru acel obiect. Același principiu se aplică și persoanelor detectate în scenă. Prin această asociere se poate observa dacă o persoană se apropie de o zonă, dacă un obiect apare lângă ea și dacă obiectul rămâne stabil după deplasarea persoanei.

În literatura de specialitate, ByteTrack este o metodă de tracking multi-obiect care asociază detecțiile între cadre și valorifică inclusiv detecțiile cu scoruri mai mici pentru a menține traiectorii mai stabile [10]. În contextul proiectului, trackingul este util deoarece reduce riscul de a interpreta aceeași apariție vizuală ca mai multe evenimente independente. De asemenea, el oferă informații despre persistența obiectului și despre relația temporală dintre persoană și deșeu.

Logica temporală folosită în aplicație urmărește mai multe indicii. În primul rând, sistemul verifică apariția sau stabilizarea unui obiect de tip deșeu. În al doilea rând, analizează dacă în apropiere există sau a existat o persoană. În al treilea rând, verifică dacă obiectul persistă în scenă suficient pentru a justifica salvarea unei dovezi. Aceste reguli nu garantează identificarea perfectă a intenției, dar reduc numărul de momente care trebuie verificate manual.

Un aspect important este evitarea alertelor repetate pentru același eveniment. Dacă un obiect rămâne în scenă mai multe secunde, sistemul nu trebuie să creeze un incident nou la fiecare cadru. Din acest motiv, logica temporală trebuie să includă mecanisme de stabilizare, ferestre de analiză și reguli de evitare a dublicării. Detaliile concrete ale acestei componente sunt prezentate în capitolele dedicate proiectării și implementării.

2.5 Metrice de evaluare pentru modele de viziune artificială

Evaluarea modelelor de viziune artificială trebuie realizată prin metrice clare, nu doar prin observații vizuale. Pentru detectorul de deșeuri, interesează atât câte obiecte reale sunt detectate, cât și câte detecții false sunt produse. Pentru clasificatorul de material, interesează cât de des eticheta estimată corespunde categoriei reale. Pentru logica temporală, evaluarea trebuie să urmărească dacă sistemul semnalează corect evenimentele relevante din clipuri video.

În cazul detecției și clasificării, se folosesc noțiunile de adevărat pozitiv, fals pozitiv, fals negativ și adevărat negativ. Un adevărat pozitiv apare atunci când sistemul identifică în mod corect un obiect sau o clasă. Un fals pozitiv apare atunci când sistemul semnalează un obiect sau o clasă care nu este corectă. Un fals negativ apare atunci când sistemul omite un obiect real. Aceste valori stau la baza metricilor principale.

Precizia arată cât de multe dintre predicțiile pozitive ale modelului sunt corecte:

$$\text{Precizie} = \frac{TP}{TP + FP}$$

Recall-ul arată cât de multe dintre exemplele reale pozitive au fost identificate de model:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Scorul F1 combină precizia și recall-ul într-o singură valoare:

$$F1 = 2 \cdot \frac{\text{Precizie} \cdot \text{Recall}}{\text{Precizie} + \text{Recall}}$$

Pentru detecția obiectelor se folosește și metrica IoU, care exprimă intersecția peste reuniune. Aceasta măsoară suprapunerea dintre caseta prezisă de model și caseta reală din setul etichetat. O detecție este considerată corectă doar dacă IoU depășește un anumit prag. Metricile mAP@50 și mAP@50–95 sunt folosite frecvent pentru evaluarea detectorilor, deoarece sintetizează performanța la unul sau mai multe praguri de suprapunere.

Pentru clasificatorul de material poate fi folosită acuratețea, dar aceasta nu este întotdeauna suficientă. Dacă unele clase apar mai des decât altele, acuratețea poate ascunde erori importante pentru clasele rare. Din acest motiv, este utilă și matricea de confuzie, care arată ce clase sunt confundate între ele. Modul de interpretare a acestor metrici este reluat în capitolul de testare, unde evaluarea este legată de fluxul aplicativ al sistemului.

2.6 Tehnologii web, baze de date și comunicare client-server

Componenta aplicativă a lucrării este dezvoltată ca sistem web local. Această alegere permite folosirea unei interfețe accesibile din browser, separarea logicii de backend de interfața utilizatorului și integrarea componentelor de inferență într-un flux controlat. Aplicația nu este doar un script de procesare video, ci o platformă în care utilizatorul poate porni monitorizarea, încărcă fișiere video, vede incidente, valide dovezi și administrează datele locale.

Backend-ul este construit cu FastAPI, un framework modern pentru API-uri Python, bazat pe tipare standard și pe suport pentru funcții asincrone. În proiect, FastAPI este potrivit deoarece permite definirea clară a endpoint-urilor, gestionarea cererilor HTTP, servirea interfeței web și integrarea WebSocket-urilor pentru fluxuri video. WebSocket-ul este important deoarece permite transmiterea repetată a cadrelor între browser și server, fără a deschide o cerere HTTP separată pentru fiecare cadru.

Prelucrarea imaginilor și a clipurilor video este realizată cu OpenCV. Biblioteca permite citirea cadrelor din fișiere video sau camere, redimensionarea imaginilor, desenarea casetelor de delimitare, salvarea thumbnail-urilor și generarea clipurilor asociate incidentelor. Clasa VideoCapture este folosită ca mecanism pentru capturarea video din fișiere, dispozitive sau fluxuri video. În aplicație, aceste operații sunt folosite pentru a transforma fluxul video într-o succesiune de cadre care pot fi analizate de modelele YOLO.

Baza de date locală este realizată cu SQLite, iar accesul la date este gestionat prin SQLAlchemy.

chemy. SQLite este potrivit pentru un prototip local deoarece funcționează ca motor de bază de date integrat, fără configurarea unui server separat. SQLAlchemy oferă un strat de lucru cu baza de date și suport pentru utilizare asincronă, ceea ce se potrivește cu structura backend-ului. În proiect, baza de date păstrează utilizatorii, incidentele, sesiunile video, statusurile de validare și metadatele dovezilor locale.

Interfața web este realizată cu HTML, CSS și JavaScript, servite prin backend. Ea oferă panouri diferite în funcție de rolul utilizatorului. Utilizatorul responsabil poate monitoriza fluxul video și valida incidentele, iar administratorul poate gestiona utilizatorii, incidentele și dovezile locale. Această separare este necesară deoarece nu toate acțiunile trebuie să fie disponibile tuturor utilizatorilor.

Din punct de vedere arhitectural, sistemul poate fi privit ca o succesiune de componente conectate: browserul transmite cadre sau fișiere video, backend-ul procesează datele, modelele YOLO realizează detecția și clasificarea, logica temporală decide dacă se creează un incident, iar baza de date păstrează starea evenimentului. Tabelul următor sintetizează rolul principalelor tehnologii utilizate.

Nivel al sistemului	Tehnologii și rol principal
Analiză vizuală	YOLOv8 și Ultralytics pentru localizarea deșeurilor, detectarea persoanelor și estimarea materialului prin clasificare pe regiunea decupată.
Procesare video	OpenCV pentru citirea cadrelor, redimensionare, adnotare vizuală, salvarea thumbnail-urilor și generarea clipurilor asociate incidentelor.
Backend și date	FastAPI, SQLite și SQLAlchemy pentru endpoint-uri HTTP, WebSocket-uri, autentificare, persistența incidentelor și gestionarea dovezilor locale.
Interfață utilizator	HTML, CSS și JavaScript pentru monitorizare, validarea incidentelor, administrare și afișarea dovezilor într-un panou web local.

Tabel 1: Rolul principalelor tehnologii utilizate în sistem

Prin combinarea acestor tehnologii, aplicația obține un flux complet, de la captarea imaginii până la gestionarea incidentului în interfață. Capitolul următor va descrie modul în care datele sunt pregătite, cum sunt organizate seturile de antrenare, validare și testare și cum sunt antrenate modelele folosite în sistem.

CAPITOLUL 3

DATE, ANTRENAREA MODELELOR ȘI METODOLOGIA EXPERIMENTALĂ

3.1 Sursele de date și selecția exemplilor

Calitatea unui sistem de viziune artificială depinde în mare măsură de datele pe care este antrenat. În cazul lucrării de față, scopul nu este doar recunoașterea unor obiecte de tip deșeu în imagini izolate, ci identificarea unor situații relevante pentru monitorizarea spațiilor verzi și a zonelor publice. Din acest motiv, selecția datelor a urmărit apropierea cât mai bună de scenariul aplicativ: obiecte abandonate pe sol, ambalaje vizibile în exterior, persoane aflate în apropierea obiectelor și fundaluri variate, specifice unor zone deschise.

Pentru detectorul de deșeuri a fost folosit setul local `parks_detect_final`, organizat în format compatibil cu YOLO. Setul conține o singură clasă de interes, numită `trash`, deoarece detectorul are rolul de a localiza obiectul de tip deșeu, nu de a decide materialul acestuia. Estimarea materialului este realizată separat de clasificator, pe regiunea decupată din imagine. Această separare reduce complexitatea detectorului și permite analiza mai clară a erorilor.

Setul final pentru detector a fost obținut prin filtrarea unor surse locale de imagini și prin eliminarea exemplilor considerate zgomotoase sau irelevante. Au fost păstrate imaginile etichetate din surse orientate către spații publice, iar sursele cu etichete slabe sau neclare au fost excluse. Această decizie este importantă deoarece un volum mare de date nu garantează automat un model mai bun. În practică, imagini etichetate greșit, obiecte foarte ambigue sau contexte care nu au legătură cu domeniul urmărit pot reduce stabilitatea modelului.

Subset	Imagini	Fișiere de etichete	Rol în lucrare
Train	6213	6213	Ajustarea parametrilor modelului în timpul antrenării.
Validare	775	775	Monitorizarea procesului de antrenare și alegerea checkpoint-ului.
Test	780	780	Evaluarea finală a detectorului pe exemple nevăzute.

Tabel 2: Structura setului de date pentru detectorul de deșeuri

Pentru clasificarea materialului a fost folosit setul local `trashnet_cls`, organizat pe direc-

toare de clase. Acesta conține cinci categorii: glass, metal, other, paper și plastic.

Clasă material	Train	Validare	Test	Total
glass	400	50	51	501
metal	328	41	41	410
other	109	13	15	137
paper	797	99	101	997
plastic	385	48	49	482
Total	2019	251	257	2527

Tabel 3: Structura setului de date pentru clasificatorul de material

Pe lângă imaginile folosite pentru antrenare, aplicația este verificată și prin clipuri video. Aceste clipuri au un rol diferit față de seturile de imagini: ele nu sunt folosite pentru antrenarea detectorului, ci pentru evaluarea fluxului complet al aplicației. În acest caz, se urmărește dacă obiectul apare în timp, dacă există o persoană în apropiere, dacă sistemul evită alertele duplicate și dacă incidentul salvat conține suficiente dovezi locale pentru verificarea manuală.

3.2 Curățarea, etichetarea și organizarea seturilor

Pregătirea datelor a urmărit trei obiective: eliminarea exemplelor necorespunzătoare, păstrarea unei împărțiri clare între antrenare, validare și testare și folosirea unui format compatibil cu pipeline-ul YOLO. Pentru detector, fiecare imagine are asociat un fișier de etichetă în care sunt memorate clasa obiectului și coordonatele normalizate ale casetei de delimitare. Deoarece detectorul are o singură clasă, valoarea clasei este 0, asociată etichetei trash.

Împărțirea setului pentru detector a fost realizată în proporție 80/10/10, cu seed fixat la valoarea 42. Folosirea unui seed fix permite reproducerea structurii setului și reduce riscul ca rezultatele să depindă de o împărțire accidental avantajoasă. Setul de test a fost păstrat separat pentru evaluare, astfel încât modelul să fie verificat pe imagini care nu au fost folosite la ajustarea parametrilor.

Curățarea datelor a inclus verificarea existenței fișierelor de etichete, excluderea imaginilor fără adnotări utile și eliminarea surselor cu calitate scăzută. Concret, au fost păstrate sursele locale parks_detect, illegal_dumping și person_trash, relevante pentru spații publice, scenarii de aruncare ilegală și relația vizuală persoană-obiect, iar sursa litter_aiengineer a fost exclusă din setul final din cauza etichetelor prea zgomotoase. Într-un proiect de detecție, etichetele greșite pot avea efecte mai grave decât imaginile lipsă, deoarece modelul învață relația dintre obiect și caseta de delimitare. Dacă o casetă este plasată greșit sau dacă un obiect relevant nu este etichetat, modelul poate fi încurajat să producă predicții instabile.

Pentru clasificatorul de material, organizarea pe directoare de clase simplifică procesul de

antrenare. Fiecare director reprezintă o etichetă, iar modelul învață să asocieze imaginea cu una dintre categoriile disponibile. Această abordare este potrivită pentru un clasificator aplicat pe crop-uri, deoarece obiectul de interes este deja localizat de detector. În aplicație, clasificatorul primește regiunea decupată din caseta de detecție și returnează categoria cu scorul cel mai mare.

3.3 Antrenarea detectorului de deșeuri

Detectorul de deșeuri este componenta care localizează obiectele relevante în cadrele video. Pentru această sarcină a fost folosită arhitectura YOLOv8s, prin transfer learning. Alegerea unei arhitecturi de dimensiune medie este un compromis între capacitatea de detecție și viteza necesară în aplicația video. Un model prea mic poate rata obiecte greu vizibile, iar un model prea mare poate îngreuna rularea locală în timp rezonabil.

Antrenarea prin transfer learning pornește de la un checkpoint existent și ajustează modelul pe setul final de deșeuri. Această strategie este potrivită pentru lucrare deoarece modelul poate reutiliza caracteristici vizuale generale, învățate anterior, și le poate adapta la domeniul urmărit. În loc să învețe de la zero forme, margini și texturi, modelul se concentrează pe diferențierea obiectelor relevante în contexte apropiate de spații publice.

Parametru	Valoare utilizată pentru detectorul final
Arhitectură	YOLOv8s
Set de date	parks_detect_final
Dimensiune imagine	640 pixeli
Batch	8
Număr maxim de epoci	150
Early stopping	patience = 25
Rata inițială de învățare	0.0002
Checkpoint promovat	models/detector/production/best.pt

Tabel 4: Configurația de antrenare pentru detectorul final

După antrenare, checkpoint-ul validat a fost promovat în directorul de producție al aplicației. Backend-ul nu citește direct din directoarele de experimente, ci din modelul stabil menționat în tabel.

3.4 Antrenarea clasificatorului de material

Pentru estimarea materialului, clasificatorul este bazat pe YOLOv8n-cls, o variantă potrivită pentru clasificarea imaginilor de dimensiuni mai mici. Modelul activ este păstrat în directorul dedicat clasificatorului B2.

Fluxul de clasificare este aplicat după detecție. Mai întâi, detectorul produce caseta de delimitare. Apoi, aplicația decupează regiunea corespunzătoare obiectului și transmite crop-ul către

clasificator. Rezultatul este o etichetă de material și un scor de încredere. Această abordare are avantajul că modelul de material nu trebuie să analizeze întreaga scenă, ci doar zona în care detectorul a găsit un obiect relevant.

Element	Descriere
Model de bază	YOLOv8n-cls
Set de date	trashnet_cls
Clase	glass, metal, other, paper, plastic
Dimensiune imagine	224 pixeli
Batch utilizat	32
Număr maxim de epoci utilizat	50
Early stopping	patience = 20
Checkpoint activ	models/classify/B2/best.pt

Tabel 5: Configurația clasificatorului de material

Într-o scenă reală, materialul poate fi dificil de estimat: o pungă transparentă poate semăna cu sticla, o hârtie murdară poate fi confundată cu alt material, iar obiectele parțial acoperite pot produce crop-uri incomplete. Aceste limite sunt analizate cantitativ în capitolul de testare, pe matricea de confuzie a claselor.

3.5 Metodologia de evaluare experimentală

Evaluarea experimentală este organizată pe trei niveluri. Primul nivel este evaluarea detectorului de deșeuri pe subsetul de test al setului `parks_detect_final`. Aici sunt urmărite metricile specifice detecției obiectelor: precizie, recall, scor F1, `mAP@50` și `mAP@50–95`. Aceste metrici arată atât calitatea localizării obiectelor, cât și echilibrul dintre detecțiile corecte și erorile produse.

Al doilea nivel este evaluarea clasificatorului de material pe subsetul de test al setului `trashnet_cls`. Pentru această componentă sunt urmărite acuratețea, precizia, recall-ul și scorul F1 pe clase. Este importantă analiza pe fiecare clasă, nu doar valoarea globală, deoarece distribuția exemplilor nu este perfect uniformă. O clasă cu mai puține exemple, precum `other`, poate influența interpretarea rezultatelor și poate necesita verificare suplimentară.

Al treilea nivel este evaluarea fluxului video și a algoritmului temporal. Această evaluare nu se reduce la o singură imagine, ci urmărește comportamentul sistemului pe secvențe: apariția obiectului, prezența persoanei, persistența obiectului după deplasare, evitarea alertelor duplicate și salvarea dovezilor locale. Pentru această etapă pot fi folosite clipuri video controlate, filmate special pentru lucrare, precum și clipuri de verificare folosite în timpul dezvoltării.

Acest capitol nu urmărește raportarea rezultatelor, ci explică datele, pregătirea și metodologia experimentală. Interpretarea detectorului, a clasificatorului și a fluxului video este tratată în capitolul dedicat testării.

CAPITOLUL 4

PROIECTAREA ȘI IMPLEMENTAREA SISTEMULUI

Acest capitol descrie trecerea de la conceptele prezentate anterior la aplicația realizată efectiv. Sistemul propus nu se limitează la rularea unui model de detecție pe imagini, ci urmărește un flux complet: preluarea sursei video, identificarea obiectelor de tip deșeu, clasificarea materialului, corelarea temporală cu prezența unei persoane, salvarea dovezilor locale și validarea incidentului de către un utilizator autorizat.

Din punct de vedere practic, aplicația a fost proiectată ca o platformă web locală, ușor de pornit și de verificat, în care modelele de inteligență artificială sunt integrate într-un backend FastAPI, iar interacțiunea cu utilizatorul se face printr-o interfață web responsivă. Această alegere permite separarea clară între partea de inferență, baza de date, logica de business și afișarea rezultatelor.

4.1 Cerințe funcționale și non-funcționale

Cerințele sistemului au fost stabilite pornind de la scenariul principal al lucrării: monitorizarea unei zone urbane sau semi-urbane în care pot apărea acțiuni de aruncare necorespunzătoare a deșeurilor. Aplicația trebuie să ajute utilizatorul să observe rapid situațiile relevante, dar fără a transforma automat o detecție într-o concluzie oficială. De aceea, fiecare alertă este tratată ca incident tehnic ce necesită validare umană.

Principalele cerințe funcționale acoperă atât fluxul de detecție, cât și partea de administrare și audit local: autentificare pe bază de cont, cu rolurile de utilizator responsabil și administrator; monitorizare video cu analiza cadrelor primite din browser și afișarea detecțiilor în timp aproape real; încărcarea unui fișier video, procesat de backend și salvat în variantă adnotată; gestionarea incidentelor, cu listare, filtrare, note și schimbări de status; administrarea utilizatorilor, a incidentelor și a statisticilor locale de stocare. Validarea acestor cerințe este reluată punctual în capitolul de testare.

Pe lângă funcțiile vizibile în interfață, au fost definite și cerințe non-funcționale. Sistemul trebuie să fie modular, pentru ca modelele să poată fi înlocuite fără rescrierea interfeței. De asemenea, aplicația trebuie să fie suficient de rapidă pentru verificări pe flux video local, să păstreze dovezile într-un mod controlat și să permită curățarea datelor după o perioadă de retenție. O altă ce-

rință importantă este trasabilitatea: un incident trebuie să păstreze data, materialul estimat, statusul de verificare, utilizatorul asociat și fișierele relevante.

4.2 Arhitectura generală a aplicației

Arhitectura sistemului este organizată pe mai multe straturi. Primul strat este interfața web, prin care utilizatorul se autentifică, pornește monitorizarea, încarcă videoclipuri și verifică incidentele. Al doilea strat este backendul, responsabil de API, autentificare, acces la baza de date și coordonarea procesării video. Al treilea strat este format din modelele de inteligență artificială și funcțiile de inferență. Ultimul strat conține baza de date și fișierele locale salvate în timpul utilizării.

Această separare a fost aleasă pentru a evita amestecarea logicii de prezentare cu logica de detecție. Interfața nu rulează modelul AI, ci trimite cadre sau fișiere către backend. Backendul aplică modelele, calculează metadatele, salvează rezultatele și întoarce către browser doar informațiile necesare pentru afișare.

Figura 1 rezumă această organizare pe straturi și evidențiază separarea dintre interfață, backend, pipeline-ul de inferență, baza de date și stocarea locală a dovezilor.




Figura 1: Arhitectura generală a sistemului

Fluxul general al unei sesiuni video poate fi rezumat astfel: utilizatorul pornește monitorizarea sau încarcă un fișier, backendul citește cadrele, modelele identifică deșeurile și persoanele, algoritmul temporal verifică apariția unui comportament suspect, iar la confirmarea tehnică a unui eveniment se creează un incident în baza de date. În paralel, interfața primește informații despre starea curentă și afișează utilizatorului rezultatele.

Pentru monitorizarea live se folosește o conexiune WebSocket. Aceasta este mai potrivită decât cererile HTTP clasice atunci când browserul trimite cadre succesive, deoarece permite comunicare continuă între client și server. Pentru încărcarea unui fișier video se folosește o cerere HTTP, iar procesarea se face separat, astfel încât utilizatorul să poată urmări ulterior statusul sesiunii.

4.3 Integrarea pipeline-ului ML în aplicație

Pipeline-ul de inferență folosește o abordare în două etape. În prima etapă, detectorul identifică zonele din imagine în care apare un obiect de tip deșeu. În a doua etapă, fiecare zonă detectată este decupată și transmisă clasificatorului de material. Această soluție este potrivită pentru proiect deoarece detectorul se concentrează pe localizarea obiectului, iar clasificatorul se ocupă de diferențierea materialelor precum plastic, hârtie, sticlă, metal sau alte categorii.

Modelele sunt încărcate o singură dată la pornirea aplicației. Această decizie reduce timpul de răspuns, deoarece greutatea modelului nu trebuie citite de pe disc la fiecare cerere. Backendul selectează automat dispozitivul disponibil, folosind placa video atunci când aceasta este disponibilă și procesorul în caz contrar. Pentru a evita conflictele între cereri paralele, apelurile către modelele YOLO sunt protejate prin blocări interne.

În cazul imaginilor încărcate, backendul decodează fișierul, redimensionează imaginea dacă este prea mare, rulează pipeline-ul detector-clasificator și salvează imaginea adnotată. În cazul fluxului video, sistemul lucrează cu cadre în format OpenCV, pentru a evita conversii inutile între JPEG și matrice de pixeli. Astfel, procesarea video rămâne mai eficientă.

Pentru scenariile de incident, simpla detecție a unui obiect nu este suficientă. Un obiect aflat deja în cadru nu trebuie raportat automat ca aruncare ilegală. Din acest motiv, pipeline-ul folosește și un detector de persoane, precum și tracking pentru obiectele detectate. Trackingul atribuie identificatori temporari obiectelor urmărite, iar acești identificatori sunt folosiți de algoritmul temporal pentru a observa schimbarea contextului de la un cadru la altul.

Integrarea ML este, astfel, împărțită în trei niveluri:

1. detecție spațială, prin localizarea obiectelor de tip deșeu;
2. clasificare semantică, prin estimarea materialului fiecărui obiect;
3. analiză temporală, prin corelarea obiectelor cu persoanele și cu evoluția scenei.

Această organizare reduce riscul de interpretare greșită a unei singure imagini. Sistemul nu caută doar prezența unui obiect, ci urmărește dacă obiectul apare sau rămâne într-un context compatibil cu abandonarea.

4.4 Algoritmul temporal pentru semnalarea incidentelor

Partea centrală a aplicației este algoritmul temporal de semnalare a incidentelor. Acesta este necesar deoarece o imagine izolată poate arăta un deșeu, dar nu poate demonstra că deșeul tocmai a fost abandonat. Pentru o alertă mai utilă, sistemul analizează succesiunea cadrelor și urmărește relația dintre persoane, obiecte și zona în care persoanele au fost prezente.

Implementarea folosește două mecanisme complementare. Primul mecanism este bazat pe zonă: atunci când o persoană părăsește cadrul sau o anumită zonă, sistemul urmărește pentru câteva secunde dacă apare un obiect nou în zona respectivă. Al doilea mecanism este bazat pe distanță: dacă un obiect apare lângă o persoană, devine static, iar persoana se îndepărtează, sistemul poate considera că există o posibilă abandonare.

Ambele mecanisme sunt completate de o fereastră de confirmare temporală, care amână salvarea alertei câteva secunde și o anulează dacă persoana revine în zona dovezii (de exemplu, pentru a ridica obiectul înapoi), precum și de o perioadă de cooldown, care blochează alertele duplicate imediat după crearea unui incident.

În varianta bazată pe zonă, detectorul trece prin stări precum CLEAR, PERSON_PRESENT și MONITORING. Atunci când nu există persoane în cadru, sistemul se află într-o stare neutră. Când apare o persoană, poziția ei este reținută. După ce persoana dispare sau părăsește zona urmărită, sistemul intră într-o perioadă de monitorizare. Dacă în această perioadă apare un obiect nou de tip deșeu în zona asociată persoanei, se formează un candidat de incident.

În varianta bazată pe distanță, pentru fiecare obiect urmărit se păstrează relația cu persoana apropiată. Obiectul poate fi în starea NEARBY, DROPPED, SEPARATING sau ABANDONED. Trecerea între aceste stări depinde de mișcarea obiectului, de distanța estimată dintre obiect și persoană și de timpul în care persoana nu mai este vizibilă. Prin această abordare, sistemul poate detecta nu doar apariția bruscă a unui obiect, ci și situația în care obiectul este lăsat jos, iar persoana se îndepărtează treptat.

Fluxul logic al algoritmului poate fi descris în următorii pași:

1. se citește cadrul curent din fluxul video;
2. se detectează obiectele de tip deșeu și persoanele;
3. se actualizează identificatorii de tracking pentru obiectele urmărite;
4. se actualizează starea temporală a zonei și a relației persoană–obiect;

5. dacă un candidat de incident este stabil pentru perioada de confirmare, se creează evenimentul;
6. se salvează metadatele în baza de date și se atașează dovezile locale.

Această logică nu elimină complet falsurile pozitive, dar face alerta mult mai relevantă decât o detecție simplă de obiect. În plus, prin păstrarea statusului pending, aplicația obligă practic la o verificare umană înainte de marcarea incidentului ca validat, arhivat sau fals pozitiv.

4.5 Backend, bază de date și securizarea platformei

Backendul este realizat în FastAPI și expune atât endpointuri HTTP, cât și conexiuni WebSocket. Endpointurile HTTP sunt folosite pentru autentificare, încărcarea fișierelor, listarea incidentelor, administrarea utilizatorilor și descărcarea dovezilor. Conexiunile WebSocket sunt folosite pentru fluxurile video, unde comunicarea continuă este mai eficientă.

La pornirea aplicației, backendul creează tabelele necesare, aplică migrațiile locale pentru coloanele lipsă, încarcă modelele de inferență și pornește mecanismul de curățare a dovezilor expirate. Această inițializare face ca proiectul să poată fi pornit local fără pași manuali complicați, ceea ce este important atât pentru dezvoltare, cât și pentru demonstrarea aplicației.

Structura bazei de date este orientată pe entitățile principale ale platformei. Cele mai importante tabele sunt prezentate în Tabelul 6. Ele permit separarea conturilor, sesiunilor de analiză, incidentelor și dovezilor asociate.

Entitate	Rol în aplicație
Organization	Grupează utilizatorii și datele unei organizații, permițând izolarea logică a informațiilor.
User	Păstrează conturile, rolurile, emailul și parola hashuită a utilizatorilor.
DetectionSession	Reține sesiunile de detecție pe imagini și rezultatele adnotate.
VideoSession	Reține procesările video, progresul, fișierele originale și rezultatele adnotate.
LitteringEvent	Stochează incidentul detectat, materialul, statusul, notele, dovezile și metadatele temporale.
MonitoredLocation	Definește locațiile monitorizate, adresa, coordonatele și sursa video asociată.

Tabel 6: Entități principale ale bazei de date

Relațiile principale dintre aceste entități sunt prezentate în Figura 2. Schema este simplificată pentru a păstra lizibilitatea și pentru a evidenția tabelele care susțin direct fluxul de utilizare al aplicației.




Figura 2: Schema logică simplificată a bazei de date utilizate în aplicație

Autentificarea se bazează pe tokenuri JWT. La autentificare, utilizatorul trimite numele de utilizator și parola, iar backendul verifică parola hashuită. Dacă datele sunt corecte, se emite un token care este trimis ulterior în cererile către API. Parolele nu sunt stocate în clar, ci sub formă hashuită cu bcrypt. În plus, aplicația include reguli minime de complexitate pentru parole și o limitare a încercărilor repetate de autentificare.

Controlul accesului este realizat prin roluri. Utilizatorul responsabil poate porni monitorizarea, încărcă fișiere video, consulta sesiunile proprii și incidentele raportate de el, precum și descărca dovezile permise. Administratorul are, în plus, acces la incidentele întregii organizații, poate modifica statusuri, adăuga note, respinge alerte ca fals pozitive, șterge definitiv dovezi și gestiona utilizatorii. Pentru fiecare incident și sesiune video se verifică atât rolul, cât și organizația asociată, astfel încât un utilizator să nu poată accesa datele altui spațiu de lucru.

Din punct de vedere al securității fișierelor, descărcarea clipurilor și thumbnailurilor se face prin backend, nu prin acces direct la directorul local. Călea fișierului este verificată astfel încât să rămână în directorul permis pentru dovezi. Această verificare reduce riscul de acces la fișiere neautorizate prin modificarea manuală a unei căi.

4.6 Interfața web și fluxurile de utilizare

Interfața web a fost proiectată pentru a susține două moduri principale de lucru: utilizarea curentă și administrarea. Utilizatorul responsabil are nevoie de o interfață simplă, orientată pe monitorizare, upload video și consultarea incidentelor proprii. Administratorul are nevoie de un panou mai dens, în care să poată verifica rapid utilizatori, incidente, statusuri și stocare.

În fluxul de monitorizare, browserul trimite cadre către server, iar serverul întoarce obiectele detectate, starea algoritmului temporal și eventualele alerte. Interfața afișează aceste informații peste zona video și permite utilizatorului să observe dacă sistemul este în stare neutră, dacă vede persoane sau dacă monitorizează zona după plecarea unei persoane. Figura 3 prezintă pagina de monitorizare a aplicației, cu sursa video, contoarele de persoane, obiecte și alerte și comenzile pentru pornirea fluxului.




Figura 3: Pagina de monitorizare live a aplicației: sursa video, contoare de persoane, obiecte și alerte, comutarea camerei și setările avansate

În fluxul de încărcare video, utilizatorul selectează un fișier, iar aplicația creează o sesiune video. Backendul procesează fișierul, salvează versiunea adnotată și actualizează progresul. La final, utilizatorul poate descărca rezultatul. Acest flux este util pentru testele din cadrul lucrării, deoarece permite rularea acelorași videoclipuri de mai multe ori și compararea comportamentului sistemului.

Fluxul de incident începe atunci când algoritmul temporal confirmă un eveniment. Sistemul creează un incident cu status pending, salvează data, materialul estimat, scorurile, metadatele despre persoană și fișierele de dovadă. Administratorul poate apoi deschide incidentul, poate vi-

zualiza thumbnailul și clipul, poate adăuga note și poate schimba statusul. Statusurile utilizate în aplicație sunt:

1. pending, pentru incident detectat și neverificat;
2. reviewed, pentru incident confirmat în urma verificării;
3. forwarded, pentru incident arhivat local sau pregătit pentru raportare;
4. dismissed, pentru incident respins ca fals pozitiv.

Figura 4 sintetizează trecerea unui eveniment de la detecția tehnică la verificarea realizată în panoul de administrare.




Figura 4: Fluxul de creare și validare a unui incident

Panoul de administrare include statistici agregate, graficul incidentelor, lista utilizatorilor și informații despre stocarea locală, calculată pe directoare și pe statusuri. Figura 5 prezintă dashboard-ul administratorului, cu indicatorii agregați și activitatea incidentelor pe ultimele 30 de zile.




Figura 5: Dashboard-ul administratorului după sesiunile de testare: incidentele detectate, rata de validare, distribuția orară și activitatea pe ultimele 30 de zile

4.7 Gestionarea dovezilor și protecția datelor

Un aspect important al sistemului este modul în care sunt gestionate dovezile. La detectarea unui incident, aplicația salvează un thumbnail și un clip scurt în directorul local destinat incidentelor. În baza de date se păstrează calea fișierelor, materialul estimat, momentul detectării, statusul, notele și un hash al imaginii reprezentative. Acest hash are rolul de a oferi o referință tehnică pentru integritatea dovezii.

Schimbarea statusului nu copiază și nu mută fișierele. Dacă administratorul confirmă, arhivează sau respinge incidentul, se modifică doar câmpul de status și eventual notele din baza de date. Această alegere simplifică gestiunea stocării și evită crearea de duplicate. Eliberarea spațiului pe disc are loc numai în două situații: ștergerea definitivă de către administrator sau curățarea automată după perioada de retenție configurată.

Fragmentul din Codul 4.1 ilustrează schematic această separare: validarea schimbă doar metadatele incidentului, în timp ce ștergerea definitivă elimină fișierele locale asociate.

```
1 # status update: files remain in place
2 event.status = new_status
3 event.notes = notes
4 session.commit()
5
6 # permanent delete: files are removed
7 for path in (event.clip_path, event.thumbnail_path):
8     remove_file_if_allowed(path)
9 session.delete(event)
10 session.commit()
```

Cod 4.1: Separarea schimbării de status de ștergerea dovezilor locale

Perioada de retenție pentru dovezile locale este configurată în aplicație și este folosită pentru a preveni acumularea fișierelor vechi. În prototipul actual, retenția este setată la 30 de zile pentru fișierele asociate incidentelor. Această valoare poate fi ajustată în funcție de cerințele instituției sau de regulile interne de păstrare a datelor.

Protecția datelor se realizează prin mai multe măsuri: autentificare obligatorie, acces diferențiat pe roluri, izolarea datelor pe organizație, verificarea căilor de fișiere și limitarea duratei de păstrare a dovezilor. Aceste măsuri sunt importante deoarece imaginile video pot conține persoane identificabile, iar prelucrarea datelor personale trebuie raportată la principiile de limitare, securizare și control al accesului prevăzute de cadrul european privind protecția datelor. Aplicația include și suport tehnic pentru anonimizarea fețelor prin blur, însă activarea acestei funcții trebuie decisă în funcție de scenariul de utilizare și de cerințele de probă.

Prin aceste mecanisme, sistemul devine mai mult decât un simplu detector vizual. El oferă

un flux organizat de lucru: detectare, creare incident, verificare, administrare și curățare controlată a dovezilor. Această structură este esențială pentru o aplicație care urmărește utilizarea practică a inteligenței artificiale într-un context urban.

Merită subliniat că forma finală a acestui flux a rezultat din rafinare iterativă, pe baza testelor practice. De exemplu, salvarea clipului de dovadă a fost mutată după încheierea ferestrei post-incident, astfel încât clipul să conțină și secunde de după alertă, iar la închiderea neașteptată a conexiunii dovada parțială este salvată oricum, pentru a nu se pierde. Asemenea detalii de robustețe nu apar în descrierea de principiu a arhitecturii, dar fac diferența între un prototip demonstrativ și o aplicație pe care un utilizator se poate baza în utilizarea curentă.

CAPITOLUL 5

TESTARE, REZULTATE ȘI INTERPRETARE

Acest capitol prezintă modul în care sistemul este verificat și interpretat ca ansamblu integrat. Testarea nu se limitează la performanța modelului de detecție, deoarece aplicația propusă are mai multe componente care trebuie să funcționeze împreună: detectorul de deșeuri, clasificatorul de material, algoritmul temporal, backendul, baza de date, stocarea locală și interfața web.

Pentru a evita o interpretare incompletă, evaluarea este organizată pe trei niveluri. Primul nivel urmărește performanța modelelor pe seturile de test. Al doilea nivel verifică fluxul video și semnalarea incidentelor în scenarii controlate sau în clipuri de verificare. Al treilea nivel validează comportamentul aplicației web din perspectiva utilizatorului responsabil și a administratorului. Accentul este pus pe coerența metodologiei, pe integrarea componentelor și pe criteriile prin care rezultatele pot fi reproduse și extinse.

5.1 Strategia de testare a sistemului

Strategia de testare urmează metodologia pe trei niveluri descrisă în capitolul anterior: evaluarea detectorului pe subsetul de test, evaluarea clasificatorului de material pe clase și evaluarea fluxului video cu algoritmul temporal, completate de validarea funcțională a aplicației web. O detecție corectă în imagine nu este suficientă dacă incidentul nu este salvat în baza de date, dacă dovada locală lipsește sau dacă administratorul nu poate modifica statusul. Din acest motiv, testarea urmărește atât performanța algoritmică, cât și stabilitatea operațională.

Pentru fiecare test se notează contextul de rulare: modelul folosit, setul de date, pragurile de încredere, sursa video și observațiile relevante, deoarece rezultatele pot depinde de pragul detectorului, de lumină, de unghiul camerei, de dimensiunea obiectului și de durata secvenței analizate.

5.2 Evaluarea detectorului de deșeuri

Detectorul de deșeuri este evaluat pe subsetul de test al setului `parks_detect_final`. Acest subset nu este folosit la antrenare, ceea ce permite o estimare mai corectă a capacității modelului de a generaliza pe imagini noi. Deoarece detectorul are o singură clasă, `trash`, accentul cade pe localizarea obiectului și pe echilibrul dintre detecțiile corecte și cele false.

Modelul activ al aplicației este păstrat în directorul de producție al detectorului, în fișierul

best.pt. Pentru reproducerea evaluării, acesta se rulează pe subsetul de test definit în fișierul dataset.yaml al setului parks_detect_final. Semnificația metricilor folosite (precizie, recall, F1, mAP@50 și mAP@50–95) a fost prezentată în capitolul de fundamente teoretice, astfel încât aici accentul cade direct pe valorile obținute și pe interpretarea lor.

Rezultatele obținute pe subsetul de test sunt prezentate în Tabelul 7. Evaluarea a fost realizată pe 780 de imagini din setul parks_detect_final, folosind modelul promovat în directorul de producție al detectorului. Pentru a lega valorile numerice de comportamentul vizual al modelului, rezultatele sunt prezentate în două forme complementare: tabelul sintetizează metricile, iar Figura 6 oferă exemple de localizare pe imagini din subsetul de test.

Indicator	Valoare	Interpretare în lucrare
Precizie	0,9234	Majoritatea detecțiilor raportate sunt corecte.
Recall	0,8229	Modelul poate rata unele obiecte mici, parțial acoperite sau slab vizibile.
F1	0,8703	Există echilibru bun între precizie și recall.
mAP@50	0,9102	Localizarea este stabilă la prag IoU de 0,50.
mAP@50–95	0,6834	Casetele rămân rezonabile și la praguri mai stricte.

Tabel 7: Rezultatele detectorului de deșeuri pe subsetul de test

Figura 6 prezintă predicții obținute cu modelul final promovat în aplicație. Exemplele sunt selectate din imagini cu contexte apropiate de tema lucrării, precum vegetație, alei, nisip, garduri și margini de carosabil, pentru a evita folosirea unor capturi izolate care nu reprezintă scenariul de monitorizare urbană.




Figura 6: Exemple de predicții generate de detectorul final pe imagini din subsetul de test

Pe baza acestor rezultate, precizia și recall-ul trebuie analizate împreună. O precizie mare, dar cu recall mic, ar însemna că modelul raportează puține alerte false, însă poate rata multe obiecte reale. Un recall mare, dar cu precizie scăzută, ar produce multe detecții false și ar încălca inutil fluxul de validare. Pentru aplicația de față este important un echilibru, deoarece incidentul final este verificat de om, dar numărul alertelor inutile trebuie menținut redus.

Pe lângă valorile numerice, interpretarea detectorului trebuie să includă exemple reprezentative: imagini cu detecții corecte, imagini cu obiecte ratate și cazuri în care fundalul poate fi confundat cu un deșeu. Aceste exemple sunt necesare deoarece valorile numerice nu explică singure cauza erorilor.

5.3 Evaluarea clasificatorului de material

Clasificatorul de material completează detectorul. După ce obiectul este localizat, regiunea detectată este decupată și transmisă clasificatorului, care estimează categoria materialului. Modelul activ este păstrat în `models/classify/B2/best.pt`, iar evaluarea se face pe subsetul de test al setului `trashnet_cls`.

Pentru această componentă, acuratețea globală trebuie completată cu analiza pe clase. Dacă o clasă este mai rară sau are exemple vizual asemănătoare cu altă clasă, acuratețea globală poate

ascunde erori importante. De exemplu, hârtia și plasticul pot fi confundate în imagini cu lumină slabă, iar sticla transparentă poate deveni dificilă pe fundal luminos.

Evaluarea pe subsetul de test include 257 de imagini, împărțite în cele cinci clase ale setului `trashnet_cls`. Rezultatele sintetice sunt prezentate în Tabelul 8. Valoarea mai mică pentru clasa `other` este explicabilă prin numărul redus de exemple și prin caracterul ambiguu al acestei clase.

Clasă	Suport	Precizie	Recall	F1
glass	51	0,9000	0,8824	0,8911
metal	41	0,8636	0,9268	0,8941
other	15	0,7333	0,7333	0,7333
paper	101	0,9515	0,9703	0,9608
plastic	49	0,9556	0,8776	0,9149
Global	257	0,8808	0,8781	0,8788

Tabel 8: Rezultatele clasificatorului de material pe subsetul de test

Clasă reală / prezisă	glass	metal	other	paper	plastic
glass	45 (88%)	4 (8%)	0 (0%)	0 (0%)	2 (4%)
metal	2 (5%)	38 (93%)	1 (2%)	0 (0%)	0 (0%)
other	0 (0%)	0 (0%)	11 (73%)	4 (27%)	0 (0%)
paper	0 (0%)	2 (2%)	1 (1%)	98 (97%)	0 (0%)
plastic	3 (6%)	0 (0%)	2 (4%)	1 (2%)	43 (88%)

Tabel 9: Matricea de confuzie a clasificatorului de material pe subsetul de test

Valorile din Tabelul 9 includ numărul de imagini și procentul raportat la clasa reală. Diagonala principală indică predicțiile corecte, iar valorile din afara diagonalei arată confuziile dintre materiale. Cea mai vizibilă confuzie apare la clasa `other`, unde 27% dintre exemple sunt încadrate ca `paper`, ceea ce confirmă caracterul ambiguu al acestei categorii.

O clasificare greșită a materialului nu invalidează incidentul, deoarece materialul este folosit ca metadată pentru filtrare și raportare, însă confuziile identificate mai sus indică unde estimarea trebuie privită cu prudență.

5.4 Evaluarea fluxului video și a algoritmului temporal

Evaluarea fluxului video este partea cea mai importantă pentru obiectivul practic al lucrării. Sistemul nu trebuie să detecteze doar un obiect, ci să observe apariția acestuia într-un context temporal. Din acest motiv, testele video includ atât scenarii cu incident real, cât și scenarii fără incident, pentru a observa dacă aplicația evită alertele nejustificate.

Scenariile propuse pentru testare sunt prezentate în Tabelul 10. Ele pot fi rulate controlat, cu mai multe materiale și mai multe distanțe față de cameră, iar clipurile folosite în dezvoltare pot

servi ca verificare preliminară a fluxului.

Scenariu	Scopul testului	Rezultat urmărit
Aruncare efectivă	Persoana aruncă obiectul, iar obiectul rămâne în cadru după plecare.	Incident creat cu dovadă locală.
Obiect existent	Obiectul este deja în scenă înainte de pornirea monitorizării.	Fără incident nou.
Trecere fără aruncare	Persoana traversează zona, dar nu lasă niciun obiect.	Fără alertă.
Obiect ridicat din nou	Persoana lasă temporar obiectul, apoi îl ia înapoi.	Evitarea alertei finale.
Ocluzie parțială	Obiectul este vizibil incomplet sau trece prin zone aglomerate.	Observarea limitelor detectorului și trackingului.

Tabel 10: Scenarii video pentru evaluarea algoritmului temporal

Pentru fiecare clip se notează: durata, materialul obiectului, unghiul camerei, momentul aproximativ al aruncării, dacă alerta a fost creată, momentul primei alerte și dacă au apărut duplicate. În cazul unui incident detectat, se verifică și existența thumbnailului, a clipului scurt și a metadatelor salvate în baza de date.

5.4.1 Test controlat cu aplicația în monitorizare live

Scenariul de aruncare efectivă a fost executat controlat cu aplicația pornită în modul de monitorizare live, folosind camera unui telefon conectat prin HTTPS la serverul local. Persoana de test a intrat în cadru cu un obiect de tip deșeu, l-a lăsat pe sol și a părăsit zona monitorizată. Sistemul a parcurs stările PERSON_PRESENT și MONITORING, a identificat apariția obiectului nou în zona asociată persoanei și a creat automat incidentul, împreună cu thumbnailul adnotat, clipul de dovadă cu cadrele dinainte și de după incident și estimarea materialului obiectului.

Testul confirmă fluxul complet de la captura camerei până la dovada locală: incidentul apare în lista de incidente cu status pending, iar clipul salvat conține adnotările generate de sistem (obiectele detectate, persoana și regiunea declanșatoare). Același comportament a fost verificat și pentru scenariile negative: un obiect aflat deja în scenă la pornirea monitorizării nu generează alertă, iar simpla trecere a unei persoane prin cadru nu deschide un incident.

5.4.2 Evaluarea pe setul de clipuri etichetate

Pentru evaluarea sistematică a algoritmului temporal a fost colectat un set de 35 de clipuri de verificare, etichetate manual într-un manifest cu rezultatul așteptat. Deoarece sistemul este proiectat pentru o cameră fixă de monitorizare, fiecare clip a fost verificat individual față de acest scenariu de operare: au fost păstrate în scor doar înregistrările continue, filmate cu cameră statică.

Au rezultat 14 clipuri valide — 8 pozitive (conțin un act de aruncare sau abandonare) și 6 negative (parcuri, treceri de persoane, plecarea unui vehicul) — iar 21 de clipuri au fost excluse motivat: compilații și segmente de televiziune cu tăieturi de scenă sau grafică suprapusă, respectiv filmări cu camera în mișcare (ținută în mână sau montată pe vehicul), incompatibile cu ipoteza camerei statice. Evaluarea a rulat pipeline-ul complet al aplicației, cu prag de detecție 0,30, prag de persoană 0,40, dimensiune de inferență 640 și analiză la fiecare al doilea cadru. Rezultatele la nivel de incident sunt sintetizate în Tabelul 11.

Indicator (nivel de incident)	Valoare
Clipuri pozitive cu incident semnalat (TP)	5 din 8
Clipuri pozitive fără alertă (FN)	3 din 8
Clipuri negative fără alertă (TN)	5 din 6
Clipuri negative cu alertă falsă (FP)	1 din 6
Precizie	0,833
Recall	0,625
Scor F1	0,714
Viteză medie de procesare	≈13 cadre/s (RTX 3050, 4GB)

Tabel 11: Rezultatele detecției incidentelor pe setul de clipuri etichetate

Rezultatele arată un compromis asumat: precizia ridicată (0,833) înseamnă că alertele emise sunt în mare majoritate justificate, iar costul este un recall moderat (0,625) pe scenele dificile. Cele trei clipuri pozitive ratate au o cauză comună: obiectul aruncat este foarte mic raportat la cadru (de exemplu, un obiect aruncat dintr-o mașină în trecere sau o scenă nocturnă), sub pragul de detecție și de stabilitate a trackingului cerute de profilul de rulare. Acest comportament concordă cu observațiile din testele live, unde detecția este fiabilă până la aproximativ 2–3 metri de cameră și scade odată cu distanța. Singura alertă falsă provine dintr-o situație vizuală cu adevărat ambiguă: un clip cu voluntari care strâng saci de gunoi într-un parc — tipar vizual aproape identic cu abandonarea (persoană lângă obiect de tip deșeu, urmată de plecare).

Rezultatul așteptat nu este lipsa totală a erorilor, ci un comportament coerent. Un sistem realist poate rata un obiect foarte mic sau poate produce o alertă falsă într-o scenă dificilă. Important este ca aceste erori să fie identificate, explicate și legate de o cauză tehnică: detector, clasificator, tracking, praguri sau calitatea filmării.

5.5 Validarea funcțională a aplicației web

Pe lângă testarea modelelor, aplicația trebuie verificată ca sistem informatic complet. Validarea funcțională urmărește dacă utilizatorii pot lucra cu platforma fără pași ambigui și dacă datele

sunt păstrate corect. Cazurile principale de testare sunt prezentate în Tabelul 12.

Funcționalitate	Comportament verificat	Criteriu de acceptare
Autentificare	Logare, token, separarea rolurilor și accesul la paginile permise.	Acces permis doar după autentificare.
Upload video	Încărcarea fișierului, procesarea și descărcarea rezultatului adnotat.	Fișier procesat fără pierderea rezultatului.
Monitorizare live	Trimiterea cadrelor prin WebSocket și afișarea detecțiilor.	Cadre analizate și afișate în interfață.
Incidente	Deschiderea incidentului, vizualizarea dovezilor și modificarea notelor.	Detaliile se salvează în baza de date.
Administrare	Schimbarea statusului, arhivarea, respingerea și ștergerea definitivă.	Statusul se modifică fără duplicarea fișierelor.
Stocare locală	Verificarea faptului că statusul nu dublează fișierele, iar ștergerea elimină dovezile.	Spațiul se eliberează doar la ștergere/retenție.

Tabel 12: Cazuri principale de testare funcțională a aplicației web

În validarea funcțională, cele două roluri sunt verificate separat. Utilizatorul responsabil trebuie să poată porni monitorizarea, încărca videoclipuri și consulta incidentele la care are acces. Administratorul trebuie să poată gestiona utilizatorii, să modifice statusul incidentelor, să adauge note, să șteargă definitiv dovezile și să consulte stocarea locală.

Figura 7 prezintă panoul de incidente după sesiunile de testare live: fiecare incident detectat are dovadă video, material estimat cu scor de încredere și status de validare, iar filtrarea se poate face după status și material. Incidentele generate în testele controlate au fost verificate individual și confirmate de administrator, ceea ce validează fluxul complet detecție–dovadă–decizie umană.




Figura 7: Panoul de incidente după testele live: dovezi video, material estimat, scoruri de încredere, statusuri de validare și filtre

5.6 Analiza erorilor și interpretarea rezultatelor

Analiza erorilor pe clipurile de verificare a condus la două îmbunătățiri structurale ale algoritmului temporal. În prima versiune, orice obiect nou apărut oriunde în cadru, în fereastra de monitorizare, era tratat ca incident; pe un clip dificil, cu mai multe persoane și vehicule, acest comportament producea opt alerte în aproximativ două minute și jumătate, multe declanșate de vehicule sau de reidentificări ale trackerului. Versiunea finală impune condiția ca obiectul nou să apară în interiorul zonei extinse în care persoana a fost văzută ultima dată, iar fereastra de confirmare anulează candidatul dacă persoana revine în zona dovezii (situația în care obiectul este ridicat înapoi). Aceste două condiții au eliminat complet alertele false produse anterior de vehicule și de obiecte mari de fundal (un autoturism, respectiv un container erau raportate ca „obiect nou”), fără a pierde incidentul real din testul controlat. Pe setul etichetat, alertele false rămase provin exclusiv din scene în care tiparul vizual persoană-deșeu-plecare există efectiv, dar fără intenție de abandonare (de exemplu, colectarea voluntară a deșeurilor).

Dincolo de aceste corecții, analiza erorilor se realizează prin legarea fiecărei probleme de componenta care a produs-o. Dacă obiectul nu apare în lista de detecții, eroarea aparține detectorului sau calității imaginii. Dacă obiectul este detectat, dar materialul este greșit, eroarea aparține clasificatorului. Dacă obiectul este detectat corect, dar incidentul nu este creat, problema este în logica temporală sau în condițiile de confirmare. Dacă incidentul este creat, dar nu poate fi modificat în interfață, problema aparține aplicației web sau permisiunilor.

Această separare este utilă deoarece sistemul este compus din mai multe etape. O valoare bună a detectorului nu garantează automat un flux video bun, iar o interfață funcțională nu compensează un model care ratează obiectele. Evaluarea finală trebuie, prin urmare, să combine metrici cantitative cu observații calitative.

Comparativ cu o abordare bazată doar pe detecția statică a obiectelor, soluția implementată introduce două niveluri suplimentare: clasificarea materialului și analiza temporală a scenei. Această alegere face sistemul mai potrivit pentru scenarii de monitorizare, deoarece incidentul este legat de evoluția scenei, nu doar de prezența unui obiect într-o imagine. În același timp, soluția rămâne dependentă de calitatea datelor și de stabilitatea trackingului, ceea ce trebuie menționat ca limitare.

5.7 Direcții viitoare de dezvoltare

Sistemul poate fi îmbunătățit în mai multe direcții. Prima direcție este extinderea setului de date cu filmări reale din mai multe zone, anotimpuri și condiții de lumină. A doua direcție este calibrarea distanțelor în funcție de poziția camerei, pentru ca relația persoană–obiect să fie estimată mai stabil. A treia direcție este folosirea unor mecanisme mai robuste de tracking, mai ales pentru scene aglomerate sau obiecte parțial ascunse.

O altă direcție este integrarea notificărilor externe, de exemplu trimiterea unui raport către un responsabil după confirmarea manuală a incidentului. De asemenea, aplicația poate fi extinsă pentru mai multe camere active simultan, cu statistici pe locații și perioade. Pentru utilizare operațională, ar fi necesară și o analiză mai detaliată a protecției datelor, inclusiv reguli clare pentru anonimizare, retenție și acces la dovezi.

O direcție cu potențial ridicat este reantrenarea periodică a detectorului folosind chiar incidente validate în aplicație. Fluxul de lucru existent produce în mod natural date etichetate: fiecare incident confirmat de administrator conține cadre reale din mediul monitorizat, cu obiectul abandonat vizibil, iar incidentele respinse ca fals pozitive indică exact tiparele vizuale care induc modelul în eroare. Colectarea acestor exemple într-un set de reantrenare ar adapta treptat detectorul la condițiile specifice fiecărei locații — iluminare, fundal, tipuri de deșeuri frecvente — și ar reduce în timp atât ratările, cât și alertele false, fără efort suplimentar de etichetare manuală.

În privința instalării operaționale, varianta naturală de evoluție este un server dedicat cu placă video, conectat la camere fixe prin fluxuri RTSP, cu praguri de detecție calibrate separat pentru fiecare cameră în funcție de distanța și unghiul de montare. Limita de detecție observată în teste, de aproximativ 2–3 metri pentru camera de telefon, s-ar putea extinde semnificativ cu camere de supraveghere cu rezoluție mai mare și cu decuparea inteligentă a zonelor de interes din cadru înainte de inferență.

Capitolul stabilește cadrul de evaluare necesar pentru verificarea sistemului și pentru reluarea testelor în condiții reproductibile. Rezultatele trebuie interpretate ca validare de concept și ca verificare a fluxului informatic, nu ca evaluare operațională pe scară largă. Toate valorile raportate provin din rulări care pot fi reproduse cu scripturile de evaluare păstrate în proiect: evaluarea detectorului și a clasificatorului pe subseturile de test, respectiv evaluarea fluxului video pe setul de clipuri etichetate în manifest. Această trasabilitate, împreună cu separarea dintre modelele de producție și experimentele de lucru, permite reluarea oricărui experiment din lucrare pe aceeași configurație sau pe una echivalentă. În ansamblu, rezultatele capitolului susțin obiectivul central al lucrării: transformarea unei detecții vizuale brute într-un incident verificabil, însoțit de dovezi

locale și integrat într-un flux de lucru cu validare umană.

O observație metodologică finală privește dimensiunea setului de evaluare video. Numărul de clipuri publice care respectă simultan condițiile scenariului — cameră fixă, înregistrare continuă, act de aruncare vizibil — este limitat, iar acest lucru restrânge setul valid de evaluare. Concluziile cantitative trebuie citite în această lumină: ele indică tendințe clare și cauze de eroare identificabile, nu intervale statistice strânse. Extinderea setului cu filmări proprii, realizate controlat în mai multe locații și condiții de iluminare, este pasul natural pentru consolidarea acestor rezultate.

CONCLUZII

Sinteza rezultatelor obținute

Lucrarea a urmărit proiectarea și implementarea unui sistem informatic pentru detectarea deșeurilor în spații verzi, cu accent pe integrarea viziunii artificiale într-un flux aplicativ complet. Problema abordată nu se limitează la recunoașterea unui obiect într-o imagine, ci include interpretarea apariției obiectului într-un context video, salvarea dovezilor locale și validarea incidentului de către o persoană responsabilă.

Soluția realizată include un pipeline de inferență format din detector de deșeuri, clasificator de material și detector de persoane. Detectorul localizează obiectele relevante, clasificatorul estimează materialul, iar logica temporală analizează relația dintre obiect, persoană și evoluția scenei. Prin această combinație, sistemul nu tratează orice obiect detectat ca incident, ci încearcă să semnaleze doar situațiile care merită verificate.

Aplicația web oferă un cadru practic pentru folosirea acestor componente. Utilizatorul responsabil poate porni monitorizarea sau încărca videoclipuri, iar administratorul poate verifica incidente, modifica statusul, adăuga note, arhiva sau șterge definitiv dovezile. Stocarea locală este organizată astfel încât schimbarea statusului să nu dubleze fișierele, iar eliberarea spațiului să apară doar la ștergere definitivă sau la aplicarea perioadei de retenție.

Lucrarea demonstrează un sistem integrat și stabilește o metodologie clară de evaluare pentru detector, clasificator și fluxul video. Accentul este pus pe integrarea componentelor, pe separarea rolurilor, pe gestionarea incidentelor și pe criteriile prin care rezultatele pot fi reproduse sau extinse ulterior. Astfel, contribuția principală nu este doar modelul de detecție, ci întregul flux informatic care transformă rezultatul modelului într-o alertă verificabilă.

Contribuții personale

Contribuțiile principale ale lucrării sunt atât algoritmice, cât și aplicative. În prima parte, au fost analizate și organizate datele necesare pentru detectorul de deșeuri și clasificatorul de material. Seturile au fost pregătite astfel încât să existe separare între antrenare, validare și testare, iar modelele active au fost păstrate în directoare clare pentru integrarea în aplicație.

O contribuție importantă este integrarea pipeline-ului ML într-un backend FastAPI. Modelele sunt încărcate la pornirea aplicației, iar inferența este conectată cu fluxurile HTTP și WebSo-

cket. Această integrare transformă modelele din componente izolate în servicii utilizabile într-o aplicație reală, în care rezultatele pot fi salvate, afișate și validate.

O altă contribuție este proiectarea algoritmului temporal pentru semnalarea incidentelor. Sistemul urmărește apariția obiectului în timp, prezența persoanei și persistența obiectului după deplasare. Această abordare este mai potrivită decât o detecție statică simplă, deoarece incidentul de aruncare sau abandonare presupune o schimbare în scenă, nu doar existența unui obiect.

La nivel de aplicație, au fost dezvoltate fluxuri pentru autentificare, roluri, monitorizare video, încărcare de fișiere, listarea incidentelor, gestionarea dovezilor și panoul de administrare. De asemenea, a fost introdusă o structură clară pentru baza de date și pentru stocarea locală, astfel încât sistemul să poată fi explicat și verificat atât din perspectivă tehnică, cât și din perspectivă funcțională.

Limitări și direcții viitoare

Sistemul propus are caracter de prototip funcțional și trebuie interpretat în limitele datelor și scenariilor testate. Performanța poate fi influențată de lumină, unghiul camerei, distanța față de obiect, dimensiunea deșeurii, ocluzie, mișcarea persoanelor și calitatea filmării. Obiectele foarte mici, transparente sau parțial ascunse pot fi mai greu de detectat, iar scenele aglomerate pot afecta stabilitatea trackingului.

O altă limitare este faptul că sistemul nu produce constatări oficiale și nu stabilește responsabilități juridice. Incidentul generat de aplicație este o alertă tehnică, însoțită de dovezi locale, care trebuie verificată de un administrator sau de o persoană responsabilă. Această limitare este importantă, deoarece păstrează rolul sistemului în zona de asistență și organizare a dovezilor, nu în zona deciziei automate.

Direcțiile viitoare includ extinderea setului de date cu filmări mai diverse, testarea în condiții diferite de lumină și anotimp, calibrarea distanțelor în funcție de amplasarea camerei și îmbunătățirea trackingului pentru situații cu ocluzii. Aplicația poate fi extinsă și pentru mai multe camere active simultan, rapoarte pe locații, notificări externe și mecanisme mai avansate de protecție a datelor.

Prin aceste îmbunătățiri, sistemul ar putea evolua de la un prototip local demonstrativ la o platformă mai robustă pentru monitorizarea asistată a spațiilor publice. Proiectul demonstrează deja legătura dintre modele de viziune artificială, analiză temporală, aplicație web și validare umană într-un flux coerent de lucru.

BIBLIOGRAFIE

- [1] Eurostat, “Municipal waste statistics,” https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Municipal_waste_statistics, 2026, [Accesat în 09.06.2026].
- [2] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You Only Look Once: Unified, real-time object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016.
- [3] G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics YOLOv8,” <https://github.com/ultralytics/ultralytics>, 2023, [Accesat în 09.06.2026].
- [4] P. F. Proenca and P. Simoes, “TACO: Trash annotations in context for litter detection,” *arXiv preprint arXiv:2003.06975*, 2020.
- [5] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollar, and C. L. Zitnick, “Microsoft COCO: Common objects in context,” in *Computer Vision – ECCV 2014*, 2014.
- [6] S. Majchrowska, A. Mikolajczyk, M. Ferlin, Z. Klawikowska, M. A. Plantykwow, A. Kwasigroch, and K. Majek, “Deep learning-based waste detection in natural and urban environments,” *Waste Management*, vol. 138, pp. 274–284, 2022.
- [7] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [8] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems*, 2012.
- [9] S. Liu, R. Chen, M. Ye, J. Luo, D. Yang, and M. Dai, “EcoDetect-YOLO: A lightweight, high-generalization methodology for real-time detection of domestic waste exposure in intricate environmental landscapes,” *Sensors*, vol. 24, no. 14, p. 4666, 2024.
- [10] Y. Zhang, P. Sun, Y. Jiang, D. Yu, F. Weng, Z. Yuan, P. Luo, W. Liu, and X. Wang, “Bytetrack: Multi-object tracking by associating every detection box,” in *European Conference on Computer Vision*, 2022.
- [11] S. Ren, K. He, R. Girshick, and J. Sun, “Faster r-cnn: Towards real-time object detection with region proposal networks,” in *Advances in Neural Information Processing Systems*, 2015.